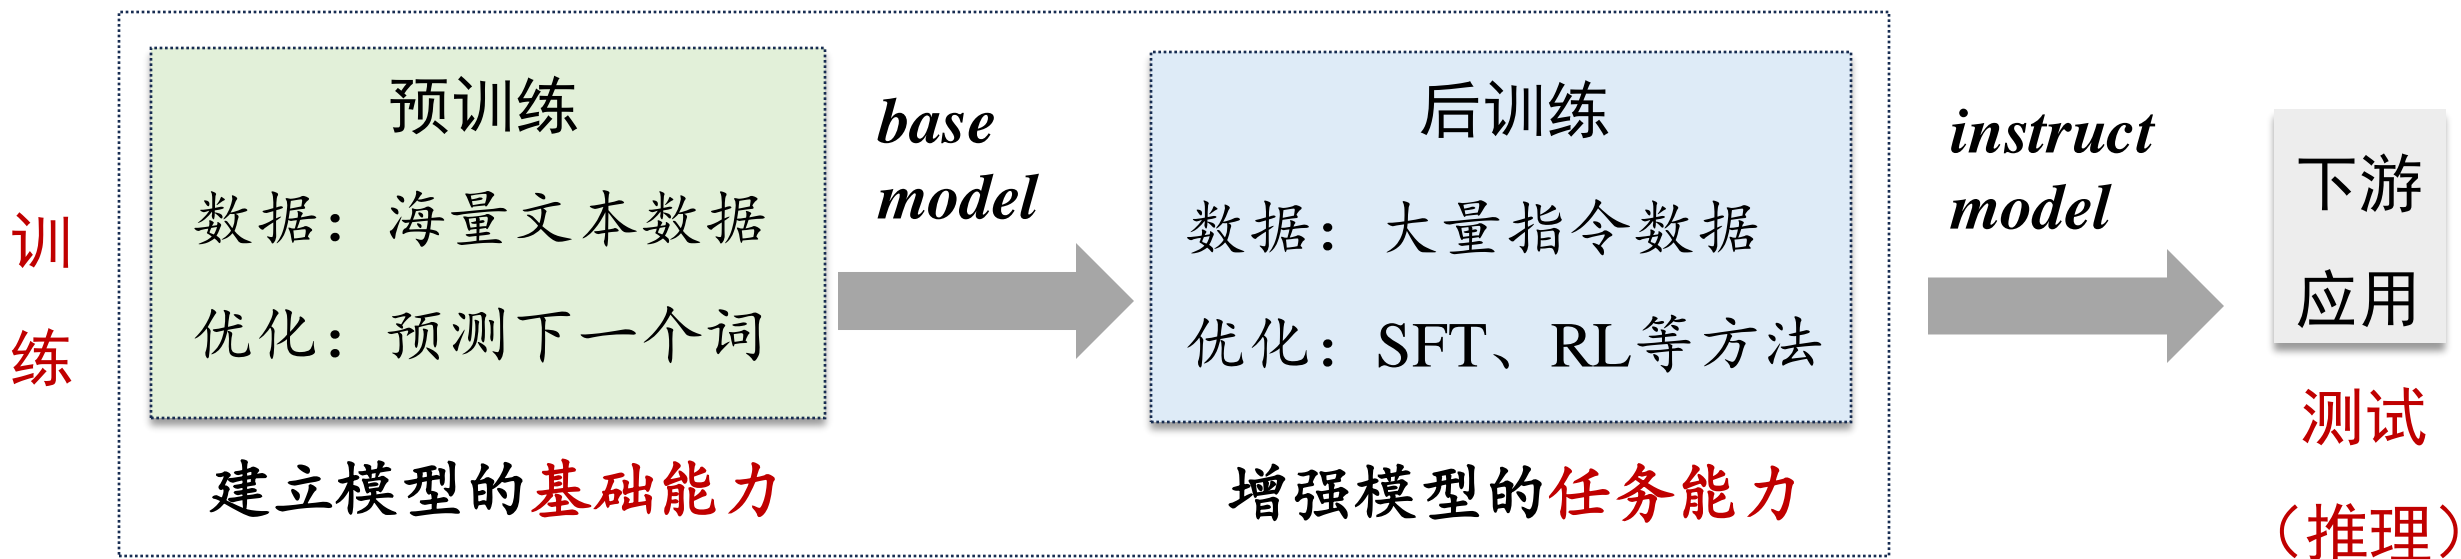


大模型技术基础

《大语言模型》编写团队：赵鑫

- 定义：通常是指具有超大规模参数的预训练语言模型
- 架构：主要为 Transformer 解码器架构
- 训练：预训练（base model）、后训练（instruct model）





- 定义：通常是指具有超大规模参数的预训练语言模型
- 架构：主要为 Transformer 解码器架构
- 训练：预训练（base model）、后训练（instruct model）

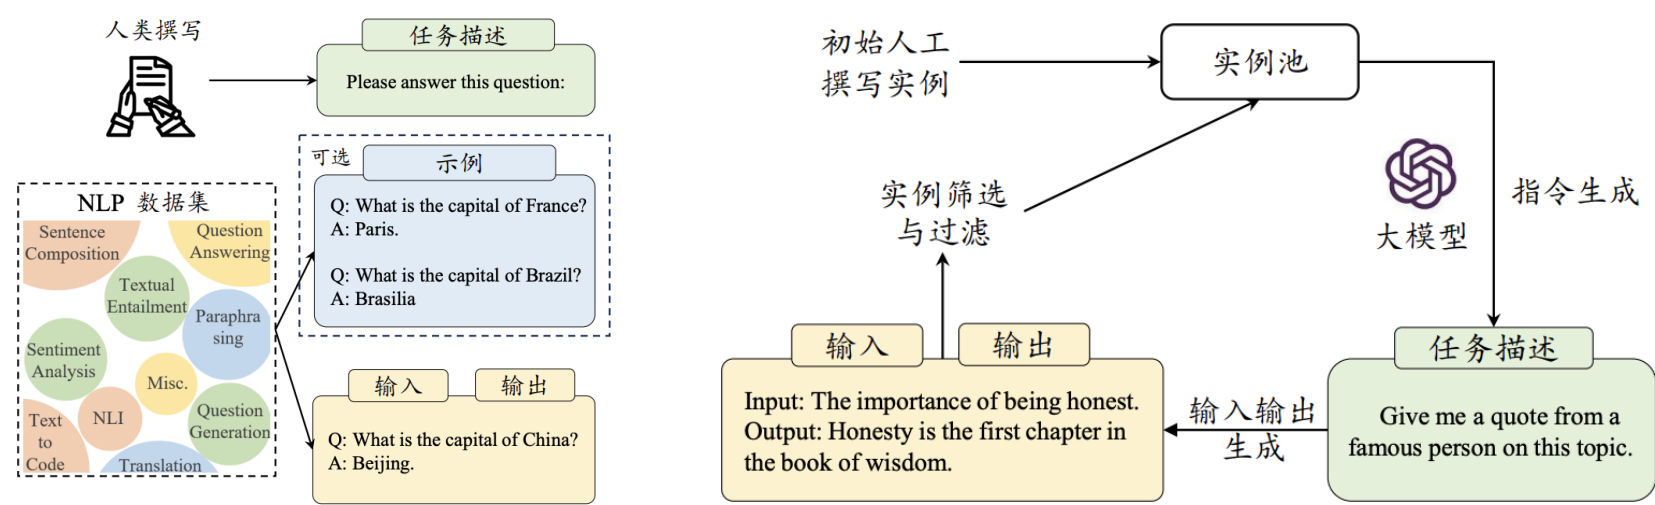
对比方面	预训练 (Pre-training)	后训练 (Post-training)
核心目标	建立模型基础能力	将基座模型适配到具体应用场景
数据资源	数万亿词元的自然语言文本	数十万、数百万到数千万指令数据
所需算力	耗费百卡、千卡甚至万卡算力数月时间	耗费数十卡、数百卡数天到数十天时间
使用方式	通常为few-shot提示	可以直接进行zero-shot使用

*此部分算力估计为一个大致估计，需要根据模型大小、数据数量、训练框架等多方面因素确定

- 大语言模型预训练（Pre-training）
 - 使用与下游任务无关的大规模数据进行模型参数的初始训练
 - 基于Transformer解码器架构，进行下一个词预测
 - 数据数量、数据质量都非常关键



- 大语言模型后训练（Post-Training）
 - 指令微调（Instruction Tuning）
 - 使用输入与输出配对的指令数据对于模型进行微调
 - 提升模型通过问答形式进行任务求解的能力

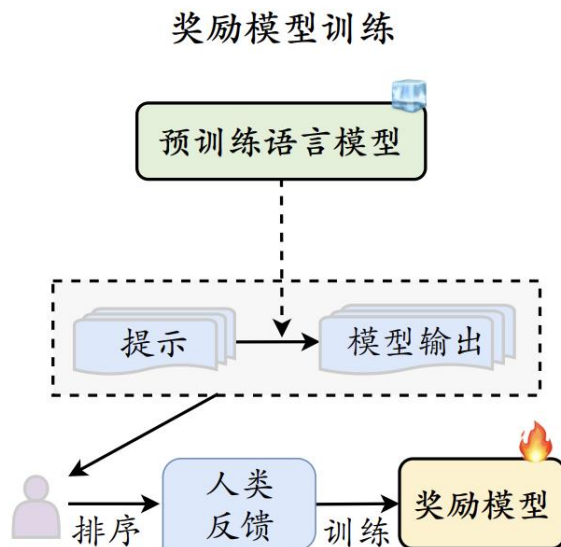
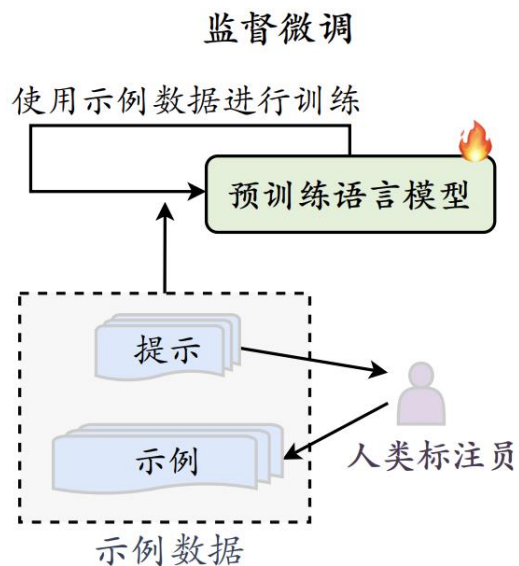


➤ 大语言模型后训练 (Post-Training)

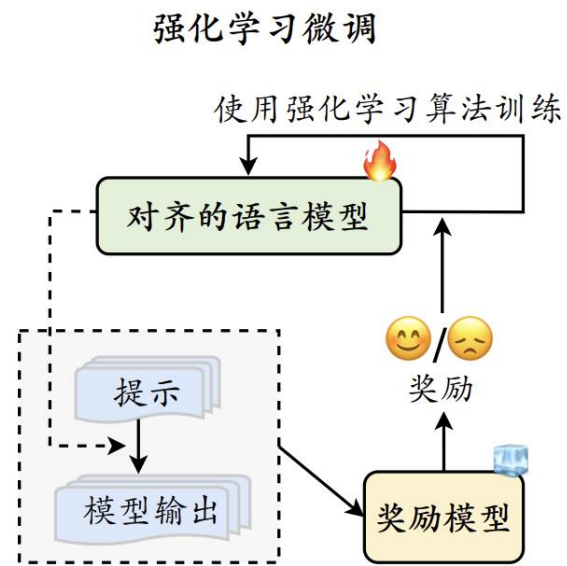
➤ 人类对齐 (Human Alignment)

➤ 将大语言模型与人类的期望、需求以及价值观对齐

➤ 基于人类反馈的强化学习对齐方法 (RLHF)



大语言模型, 2025




《大语言模型》教材课件

Authorship, Credit Attribution, and Acknowledgements

《大语言模型》教材课件

➤ 什么是扩展定律


- 通过扩展参数规模、数据规模和计算算力，大语言模型的能力会出现显著提升
- 扩展定律在本次大模型浪潮中起到了重要作用



➤ KM扩展定律

- OpenAI 团队建立了神经语言模型性能与参数规模 (N)、数据规模 (D) 和计算算力 (C) 之间的幂律关系

$$\begin{aligned} L(N) &= \left(\frac{N_c}{N} \right)^{\alpha_N}, \quad \alpha_N \sim 0.076, N_c \sim 8.8 \times 10^{13} \\ L(D) &= \left(\frac{D_c}{D} \right)^{\alpha_D}, \quad \alpha_D \sim 0.095, D_c \sim 5.4 \times 10^{13} \\ L(C) &= \left(\frac{C_c}{C} \right)^{\alpha_C}, \quad \alpha_C \sim 0.050, C_c \sim 3.1 \times 10^8 \end{aligned}$$




➤ Chinchilla扩展定律

- DeepMind 团队于 2022 年提出了另一种形式的扩展定律,旨在指导大语言模型充分利用给定的算力资源优化训练

$$L(N, D) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta},$$

$$N_{\text{opt}}(C) = G \left(\frac{C}{6} \right)^a, \quad D_{\text{opt}}(C) = G^{-1} \left(\frac{C}{6} \right)^b,$$



➤ 深入讨论

➤ 模型的语言建模损失可以进行下述分解

$$L(x) = \underbrace{L_{\infty}}_{\text{不可约损失}} + \underbrace{\left(\frac{x_0}{x}\right)^{\alpha_x}}_{\text{可约损失}}$$

可约损失：真实分布和模型分布之间KL散度，可通过优化减少
不可约损失：真实数据分布的熵，无法通过优化减少


➤ 扩展定律可能存在边际效益递减

- 随着模型参数、数据数量的扩展，模型性能增益将逐渐减小
- 目前开放数据已经接近枯竭，难以支持扩展定律的持续推进


➤ 深入讨论

➤ 可预测的扩展 (Predictable Scaling)

- 使用小模型性能去预估大模型的性能，或帮助超参数选择
- 训练过程中使用模型早期性能来预估后续性能



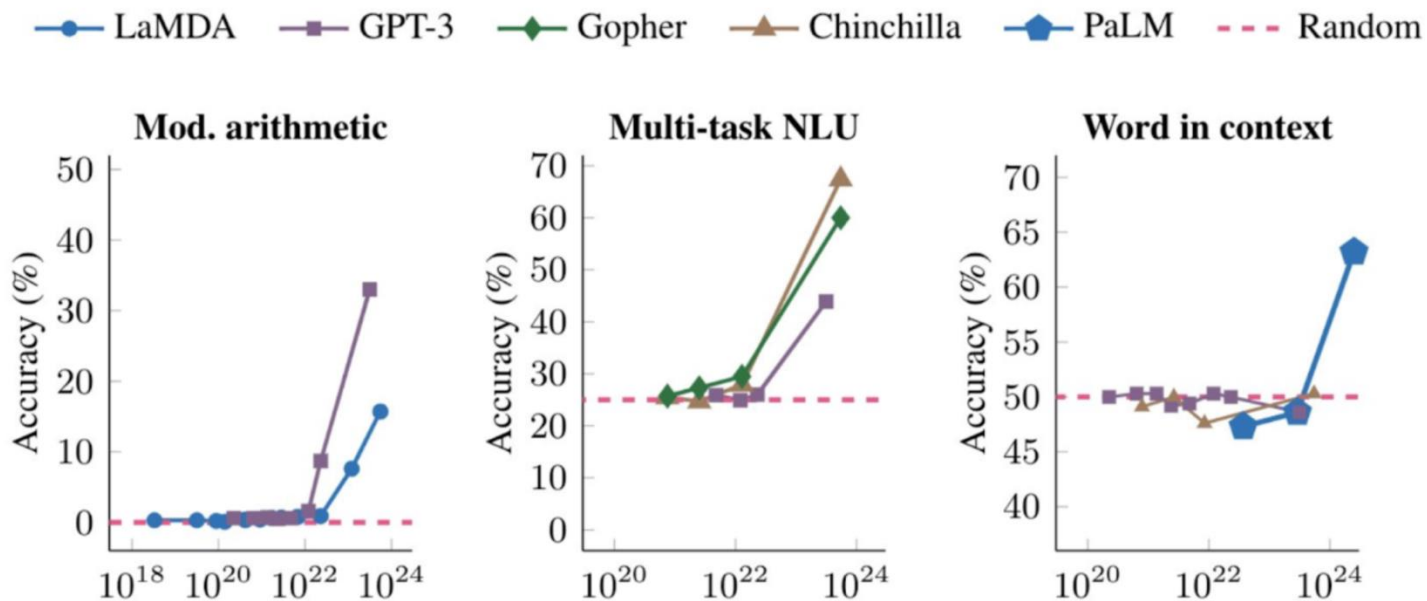
(a) Batch size scaling curve



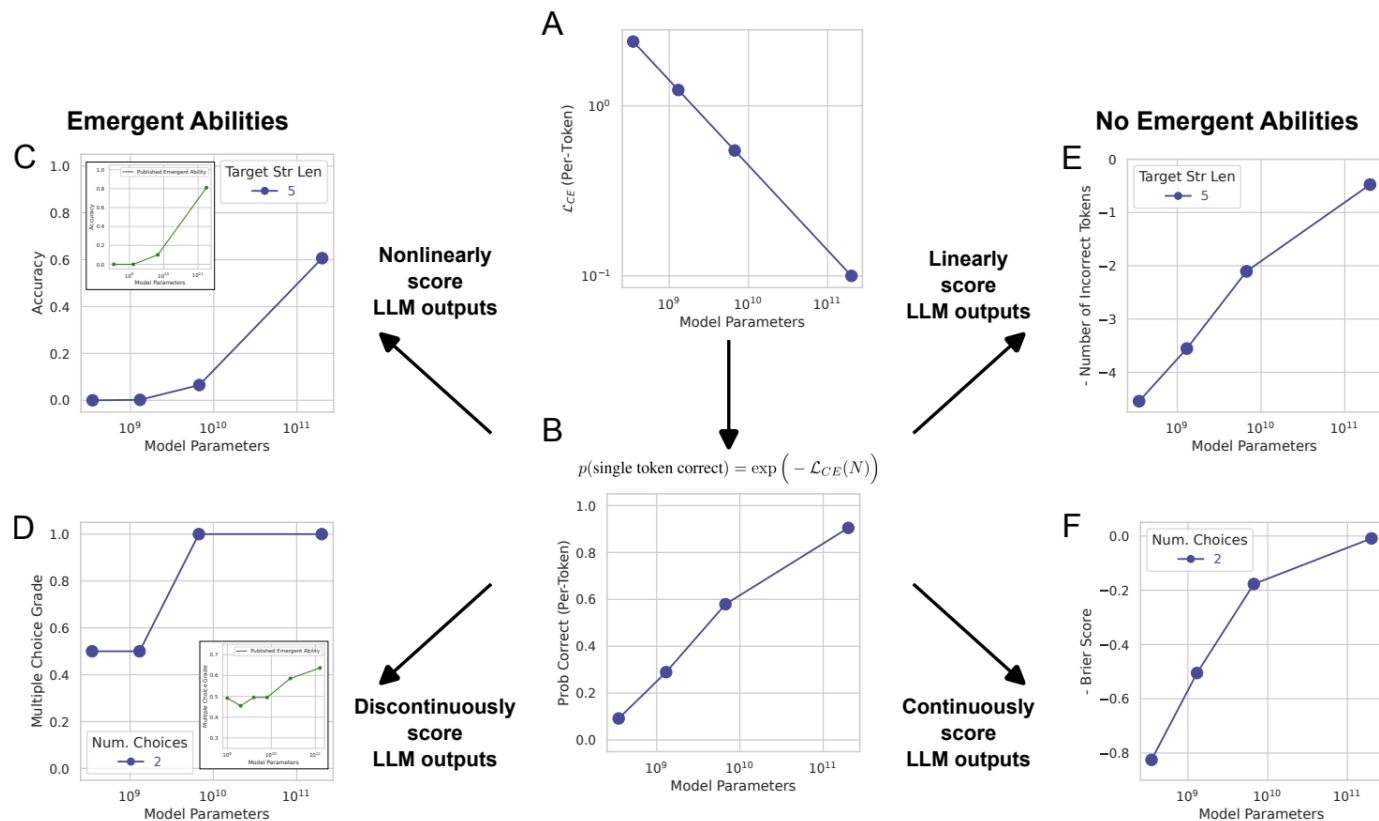
(b) Learning rate scaling curve

➤ 什么是涌现能力

- 原始论文定义：“在小型模型中不存在、但在大模型中出现的能力”
- 模型扩展到一定规模时，特定任务性能突然出现显著跃升趋势，远超随机水平



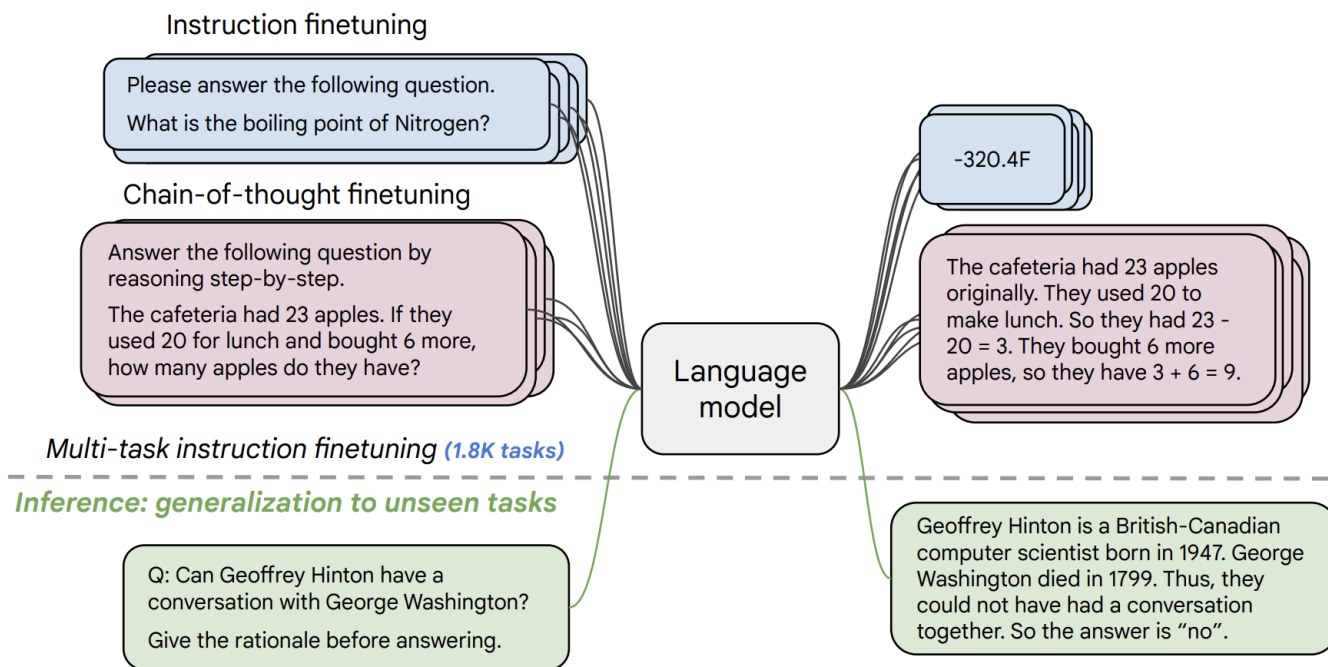
- 涌现能力可能部分归因于评测设置
 - 本课程定义其为“**代表性能力**”，并不区分是否在小模型中存在



➤ 代表性能力

➤ 指令遵循 (Instruction Following)

➤ 大语言模型能够按照自然语言指令来执行对应的任务



➤ 代表性能力

➤ 上下文学习 (In-context Learning)

- 在提示中为语言模型提供自然语言指令和任务示例，无需显式梯度更新就能为测试样本生成预期输出


$N \times$

Answer the following mathematical reasoning questions:

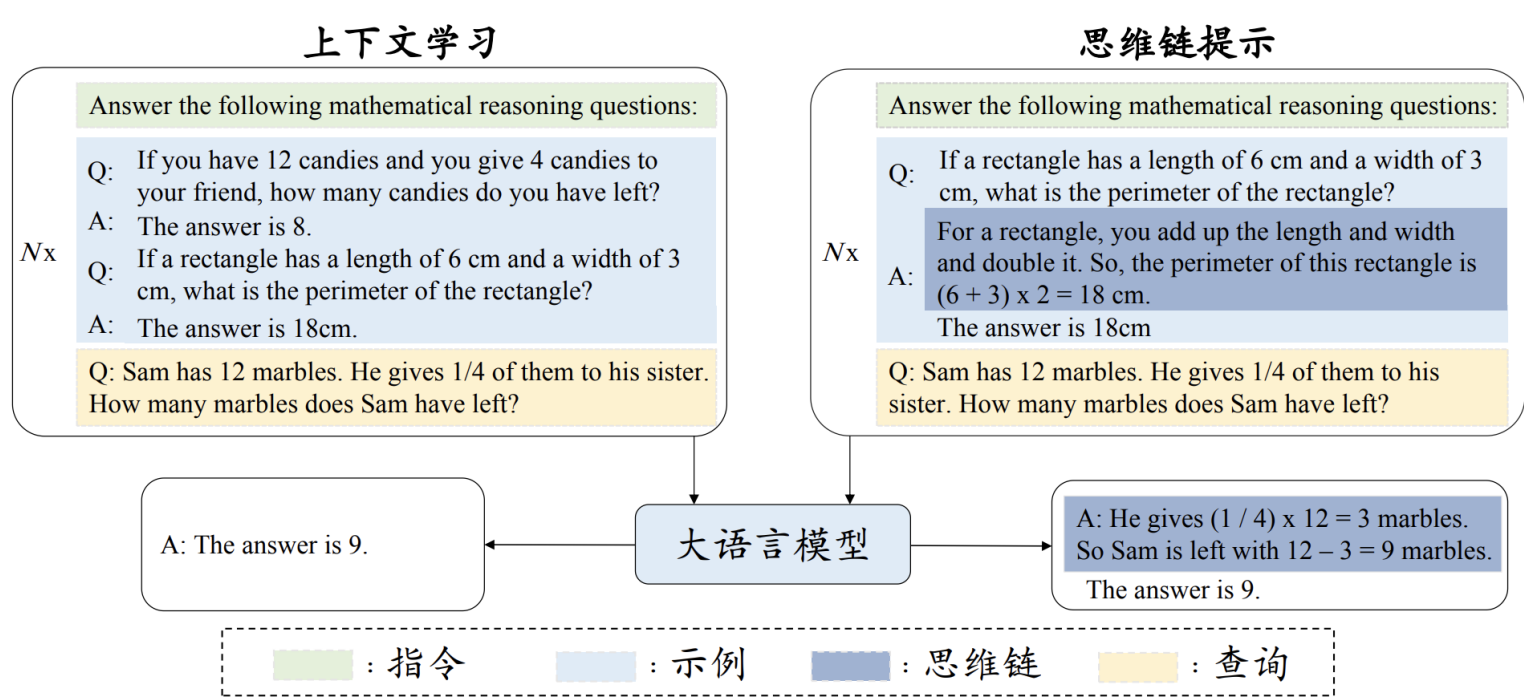
Q: If you have 12 candies and you give 4 candies to your friend, how many candies do you have left?
A: The answer is 8.

Q: If a rectangle has a length of 6 cm and a width of 3 cm, what is the perimeter of the rectangle?
A: The answer is 18cm.

Q: Sam has 12 marbles. He gives 1/4 of them to his sister. How many marbles does Sam have left?



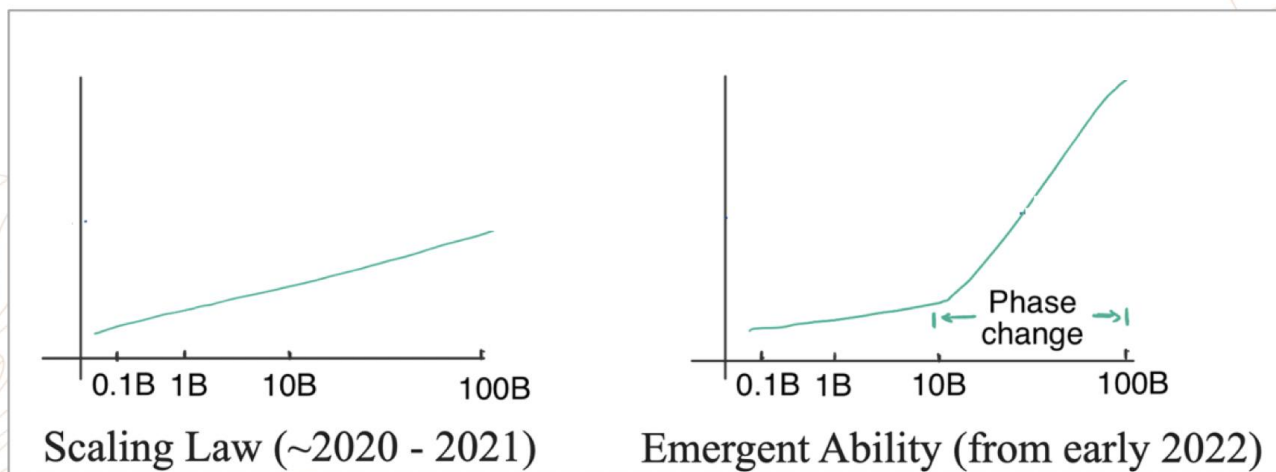
- 代表性能力
 - 逐步推理 (Step-by-step Reasoning)
 - 在提示中引入任务相关的中间推理步骤来加强复杂任务的求解，从而获得更可靠的答案



- 涌现能力与扩展定律的关系
 - 涌现能力和扩展定律是两种描述规模效应的度量方法

Scaling law describes a *predictable* increase pattern, but with *diminishing return*

可以理解为是一种较为平滑的多任务损失平均 (LM loss)



Model scaling is the key to the emergence of strong abilities

Emergent abilities transcend the scaling law, making the increase *unpredictable but profitable*

非平滑的、某种特定能力或任务的性能跃升 (Task loss)

➤ 大模型核心技术

- 规模扩展：扩展定律奠定了早期大模型的技术路线，产生了巨大的性能提升
- 数据工程：数据数量、数据质量以及配制方法极其关键
- 高效预训练：需要建立可预测、可扩展的大规模训练架构
- 能力激发：预训练后可以通过微调、对齐、提示工程等技术进行能力激活
- 人类对齐：需要设计对齐技术减少模型使用风险，并进一步提升模型性能
- 工具使用：使用外部工具加强模型的弱点，拓展其能力范围



谢谢