AI Box

预训练之训练技术

《大语言模型》编写团队：唐天一

优化参数设置

AI Box

➢ 现有大语言模型的预训练优化设置

模型	批次大小	学习率 （预热 → 峰值 → 衰减）	优化器	精度类型	权重衰减	梯度裁剪
GPT-3	32K → 3.2M	预热 → 6×10^{-5} → 余弦	Adam	FP16	0.1	1.0
OPT	2M	预热 → 1.2×10^{-4} → 手动	AdamW	FP16	0.1	-
PaLM	1M → 4M	1×10^{-2} → 平方根倒数	Adafactor	BF16	lr^2	1.0
BLOOM	4M	预热 → 6×10^{-5} → 余弦	Adam	BF16	0.1	1.0
LLaMA-2	4M	预热 → 1.5×10^{-4} → 余弦	AdamW	-	0.1	1.0
Baichuan-2	-	预热 → 1.5×10^{-4} → 余弦	AdamW	BF16	0.1	0.5
Qwen-1.5	4M	预热 → 3×10^{-4} → 余弦	AdamW	BF16	0.1	1.0
InternLM-2	5M	预热 → 3×10^{-4} → 余弦	AdamW	-	0.1	-
Falcon	预热 → 4M	预热 → 1.25×10^{-4} → 余弦	AdamW	BF16	0.1	0.4
DeepSeek	18M	预热 → 3.2×10^{-4} → 余弦	AdamW	BF16	0.1	1.0
YuLan	4.5M	预热 → 3×10^{-4} → 余弦	Adam	BF16	0.1	1.0
GLM-130B	0.4M → 8.25M	预热 → 8×10^{-5} → 余弦	AdamW	FP16	0.1	1.0

动态批次调整　学习率预热与衰减　混合精度训练

3D 并行训练

数据并行

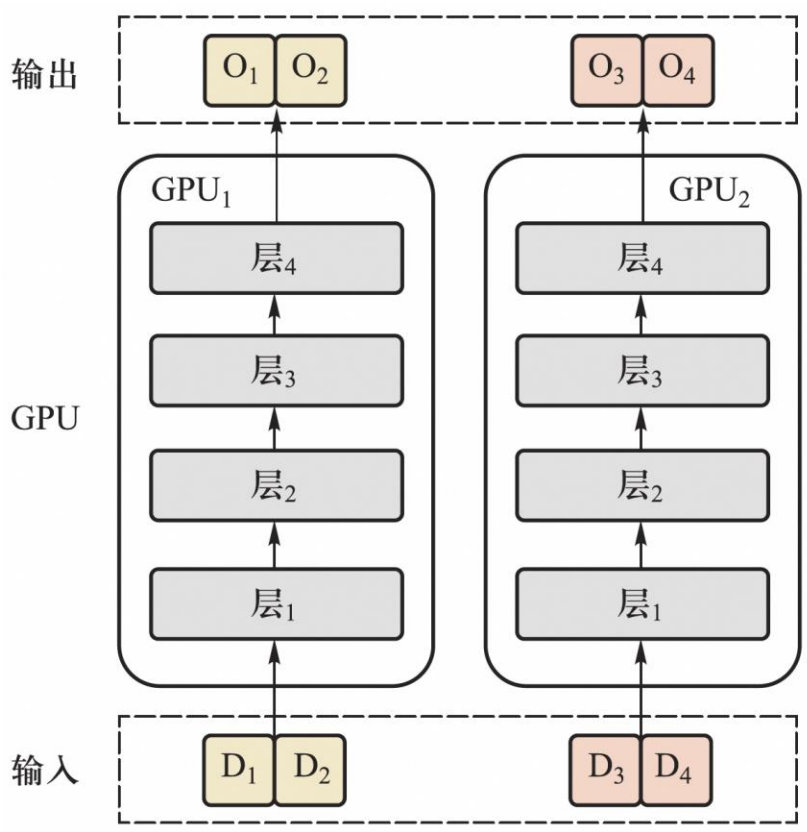

将模型复制、数据平均分配

分别计算后合并梯度，统一更新

零冗余优化器（ZeRO）

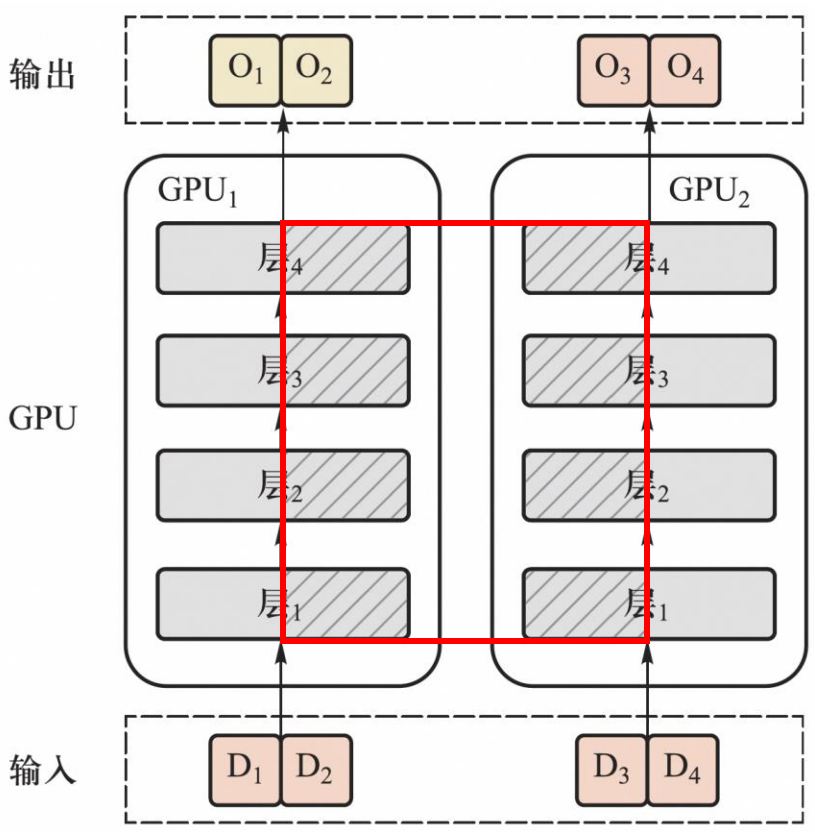

将模型均分到不同卡，缓解冗余

计算时动态从对应卡读取参数

划线部分不长期存储

需要时动态获取

3D 并行训练

AI Box

张量并行

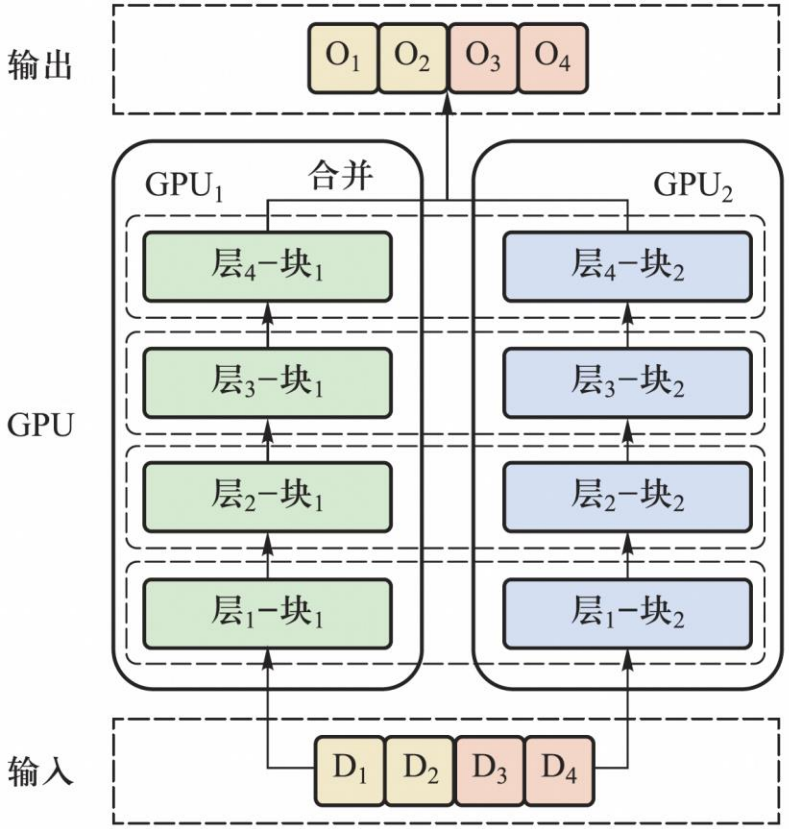

将模型参数$\boldsymbol{W}$拆分为$\boldsymbol{W}_1$和$\boldsymbol{W}_2$

在两张卡并行计算$\boldsymbol{XW}_i$后拼接得到输出

流水线并行

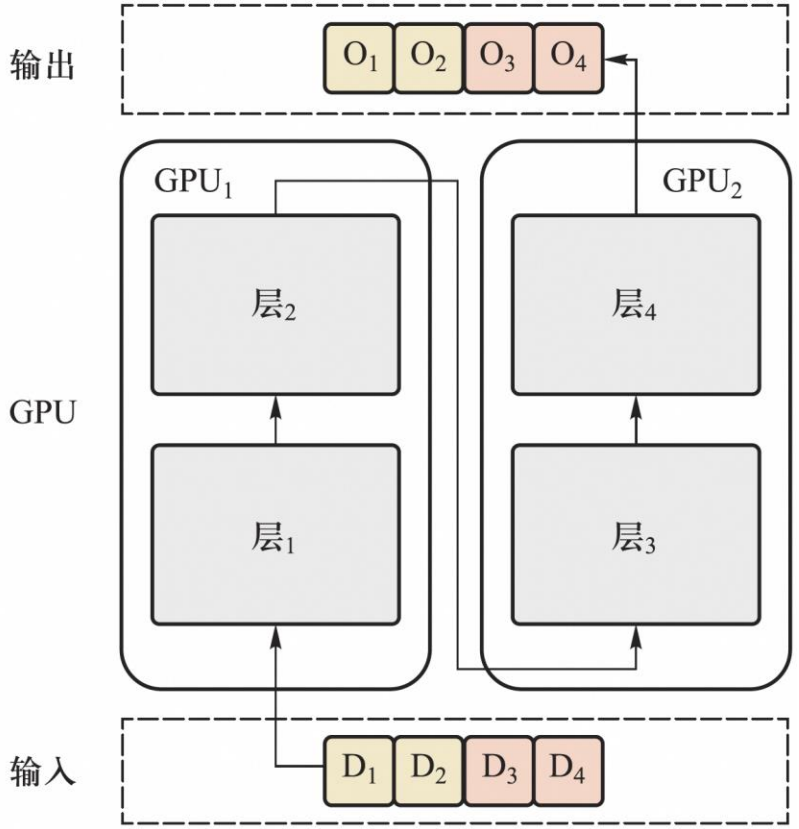

将连续的层分配到不同卡

依次经过每卡串行计算

需要与梯度累积联合使用，

以达到流水线效果

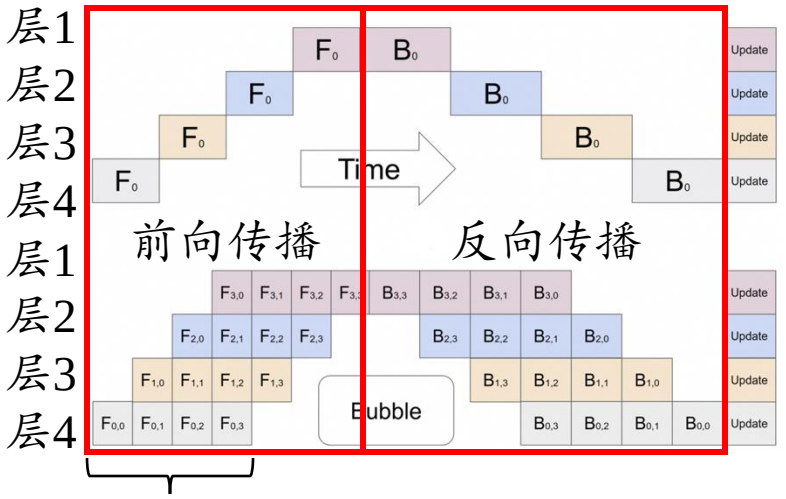

GPipe: Efficient Training of Giant Neural Networks using Pipeline Parallelism, **NeurIPS 2024**

激活重计算

AI Box

- 激活值是前向传播的结果，需要在反向传播时参与梯度计算

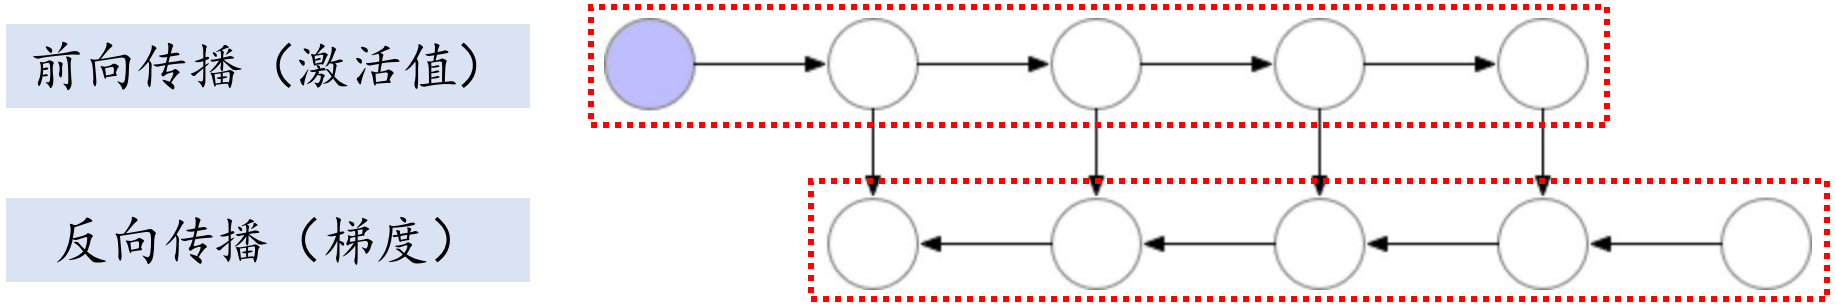

- 保存激活值需要占用大量显存

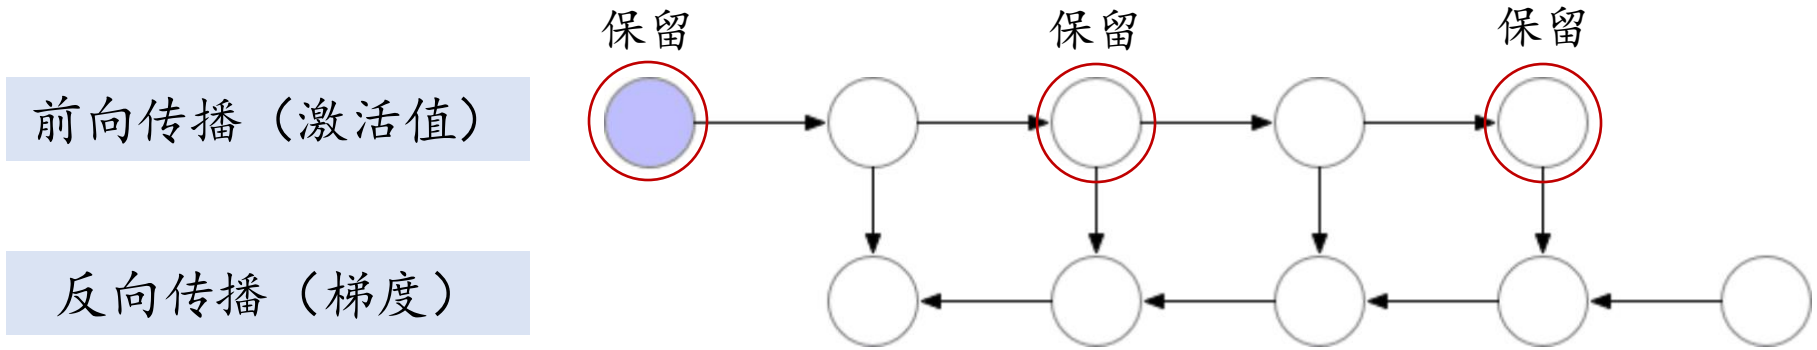

- 激活重计算：保留部分激活值，反向传播时重新计算其他激活值

混合精度训练

- 同时使用 32 位浮点数和 16 浮点数计算
- 显存减半、效率翻倍
  - DeepSeek-V3 使用 FP8 混合训练，进一步减少密集型计算开销

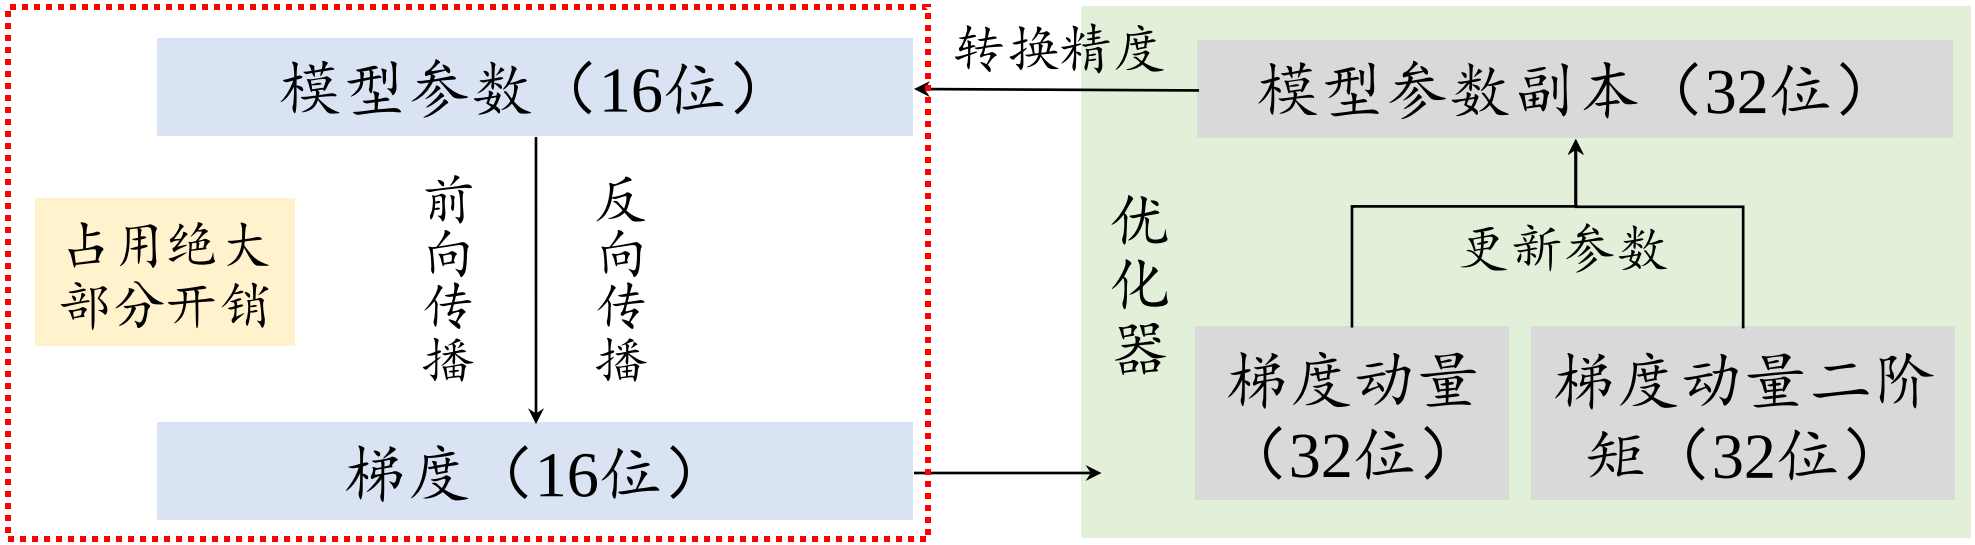

模型参数量估计

AI Box

- LLaMA 模型参数量如何计算？
  - Transformer 层数 L
  - 隐含层维度 H
  - 中间状态维度 H'
  - 注意力头数 N
  - 上下文窗口长度 T
  - 词表大小 V

# params	7B	13B	33B	65B	7B	13B	34B	70B	8B			70B
# training tokens	1T	1T	1.4T	1.4T	2T	2T	2T	2T	15T			15T
hidden embed dim	4096	5120	6656	8192	4096	5120		8192	4096			8192
# attn heads	32	40	52	64	32	40		64	32			64
# attn layers	32	40	60	80	32	40		80	32			80
attention	MHA	MHA	MHA	MHA	MHA	MHA	GQA	GQA	GQA			GQA
# kv heads	32	40	52	64	32	40		8	8			8
nlp intermediate size	11008	13824	17920	22016	11008	13824		28672	14336			28672
context	2048				4096				8192			
tokenizer	BPE sentencepiece				BPE sentencepiece				BPE tiktoken			
token vocabulary	32000				32000				128256			
fine-tuned models	-				Llama-2-Chat (Jul 2023)...				Llama-3-Instruct (Apr 2024)			

模型参数量估计

- 输入词嵌入层
  - $\boldsymbol{E} \in \mathbb{R}^{V \times H}$，参数量$VH$
- 输出层
  - $\boldsymbol{O} = \text{softmax}(\boldsymbol{YW})$，$\boldsymbol{W} \in \mathbb{R}^{H \times V}$
  - 参数量VH
- 归一化层（2L+1层）
  - $\boldsymbol{x} = \frac{\boldsymbol{x}}{\text{RMS}(\boldsymbol{x})} \cdot \boldsymbol{\gamma}$，$\boldsymbol{\gamma} \in \mathbb{R}^{H}$
  - 参数量$(2\text{L} + 1)H$

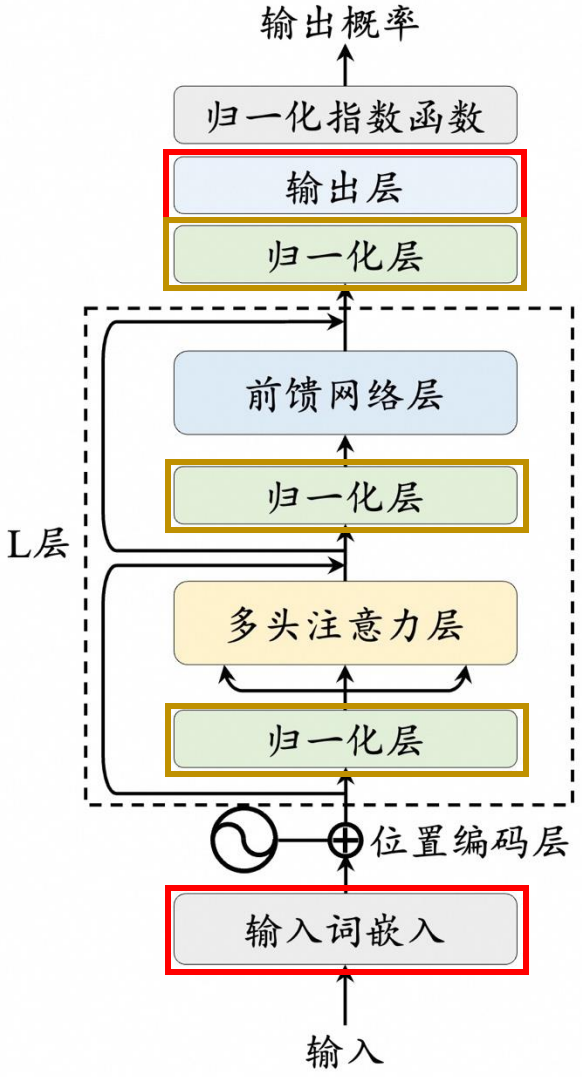

模型参数量估计

- 多头注意力层（L层）

$$\boldsymbol{Q} = \boldsymbol{X}\boldsymbol{W}^{Q}$$

$$\boldsymbol{K} = \boldsymbol{X}\boldsymbol{W}^{K}$$

$$\boldsymbol{V} = \boldsymbol{X}\boldsymbol{W}^{V}$$

$$\text{Attention}(\boldsymbol{Q}, \boldsymbol{K}, \boldsymbol{V}) = \text{softmax}\left(\frac{\boldsymbol{Q}\boldsymbol{K}^{\top}}{\sqrt{D}}\right)\boldsymbol{V}$$

$$\text{MHA} = \text{Concat}(\text{head}_1, \cdots, \text{head}_N)\boldsymbol{W}^{O}$$

- $\boldsymbol{W}^{Q}, \boldsymbol{W}^{K}, \boldsymbol{W}^{V}, \boldsymbol{W}^{O} \in \mathbb{R}^{H\times H}$，参数量共$4LH^2$

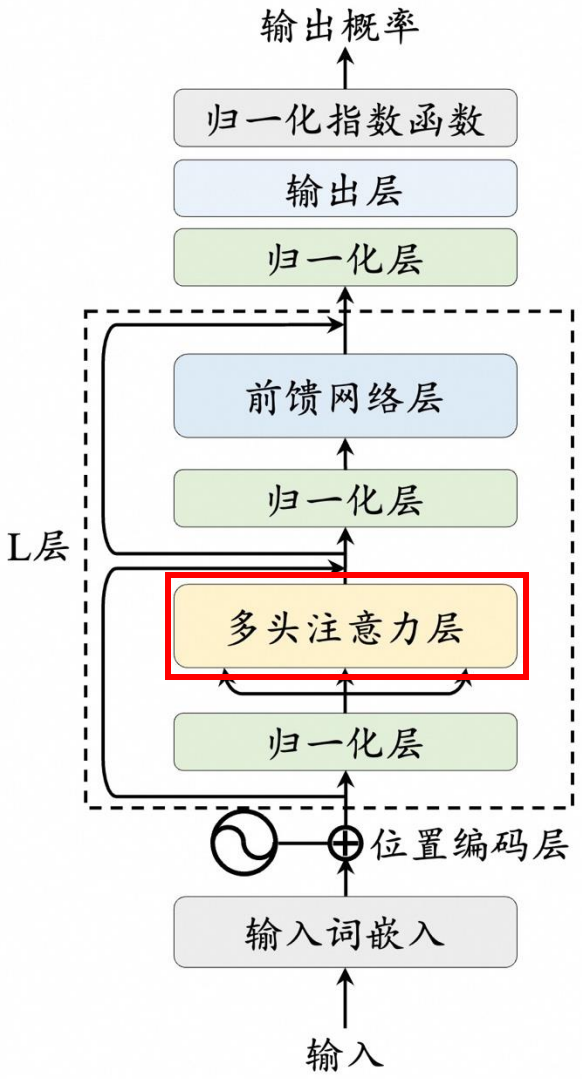

模型参数量估计

- 前馈网络层（L层）

$$\boldsymbol{G} = \boldsymbol{X}\boldsymbol{W}^{G}$$

$$\boldsymbol{U} = \boldsymbol{X}\boldsymbol{W}^{U}$$

$$\boldsymbol{D} = \mathrm{Swish}(\boldsymbol{G}) \odot \boldsymbol{U}$$

$$\boldsymbol{X} = \boldsymbol{D}\boldsymbol{W}^{D}$$

- $\boldsymbol{W}^{G}, \boldsymbol{W}^{U} \in \mathbb{R}^{H \times H'}, \boldsymbol{W}^{D} \in \mathbb{R}^{H' \times H}$
  - 参数量 $3LHH'$

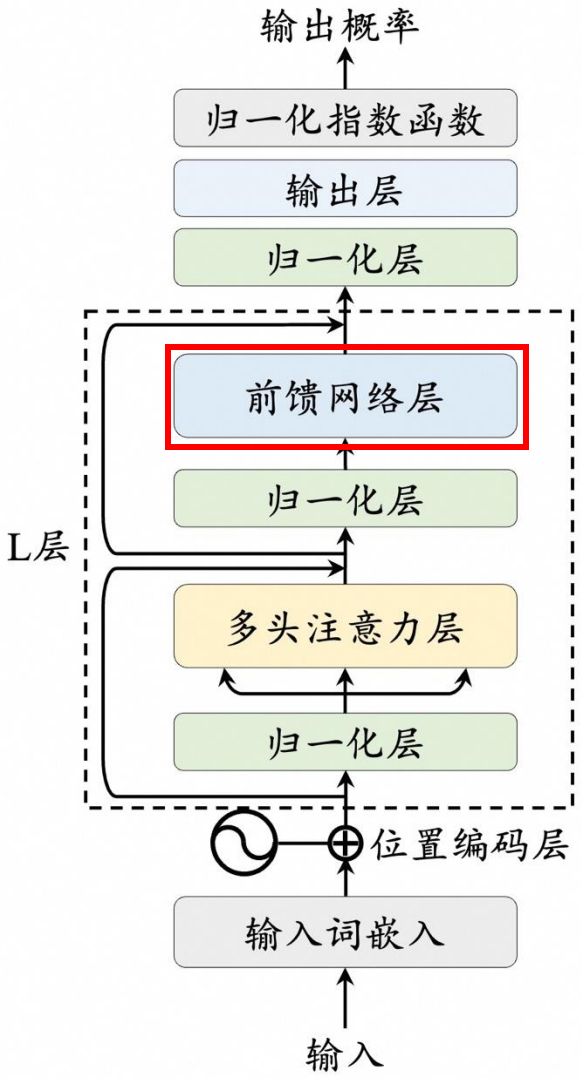

模型参数量估计

- LLaMA的参数量为：

$$\underbrace{2VH}_{\text{输入输出}} + \underbrace{H}_{\text{归一化}} + L\,(\underbrace{4H^2}_{\text{注意力}} + \underbrace{3HH'}_{\text{前馈网络}} + \underbrace{2H}_{\text{归一化}})$$

- LLaMA 7B
  - $V = 32000,\ L = 32,\ H = 4096,\ H' = 11008$
  - 参数量为6,738,415,616
- LLaMA 65B
  - $V = 32000,\ L = 80,\ H = 8192,\ H' = 22016$
  - 参数量为65,285,660,672

训练显存估计

AI Box

- 训练模型需要多少显存？
- 训练时显存占用包括以下三部分
  - 模型参数与优化器的显存占用
  - 激活值的显存占用
  - 其他显存占用

田渊栋等人新作：突破内存瓶颈，让一块4090预训练7B大模型

编辑：陈萍、大盘鸡只用 24G 显存，消费级 GPU 就能搞定大模型了。上...

11 month(s) ago

24GB单卡全量微调Llama 3-8B，仅需添加一行代码

举例来说，当训练一个拥有70亿个参数的模型时，以上参数将占用超过1...

10 month(s) ago

只需单卡RTX 3090，低比特量化训练就能实现LLaMA-3 8B全参微调

例如，即便是相对较小的 7B 规模模型，也可能需要高达 60GB 的 GPU...

9 month(s) ago

LLaMA微调显存需求减半，清华提出4比特优化器

但相比之下，单个 gpu 的显存大小却增长缓慢，这让显存成为了大模型...

2023/9/8

用FP8训练大模型有多香？微软：比BF16快64%，省42%内存

在训练前向和后向传递中全程使用 FP8 格式，极大降低了系统的计算，显...

2023/11/2

650亿参数，8块GPU就能全参数微调：邱锡鹏团队把大模型门槛打下来了

全参数微调的显存使用量和推理一样多，大模型不再只是大型科技公司...

2023/6/20

训练显存估计

- 模型参数与优化器占用
  - 模型参数量为 P，模型、梯度、优化器共计需要 $16P$ 比特显存
  - 例如 7B 模型需要 16*7B=112GB 显存占用

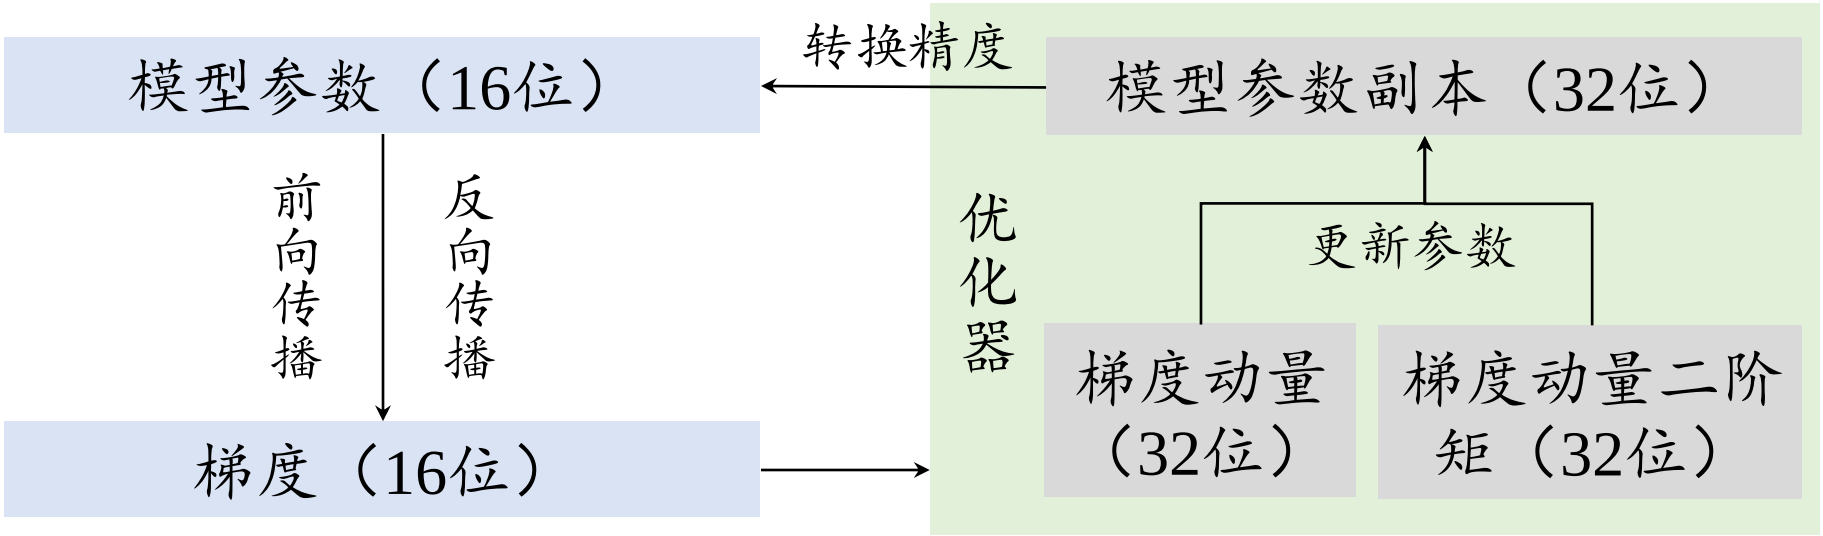

Mixed Precision Training, **ICLR 2018**

训练显存估计

AI Box

- 配合 ZeRO 技术将模型参数与优化器占用分配到每个 GPU
- N 张 GPU，使用 ZeRO-3 每张 GPU 显存占用 $\frac{16P}{N}$

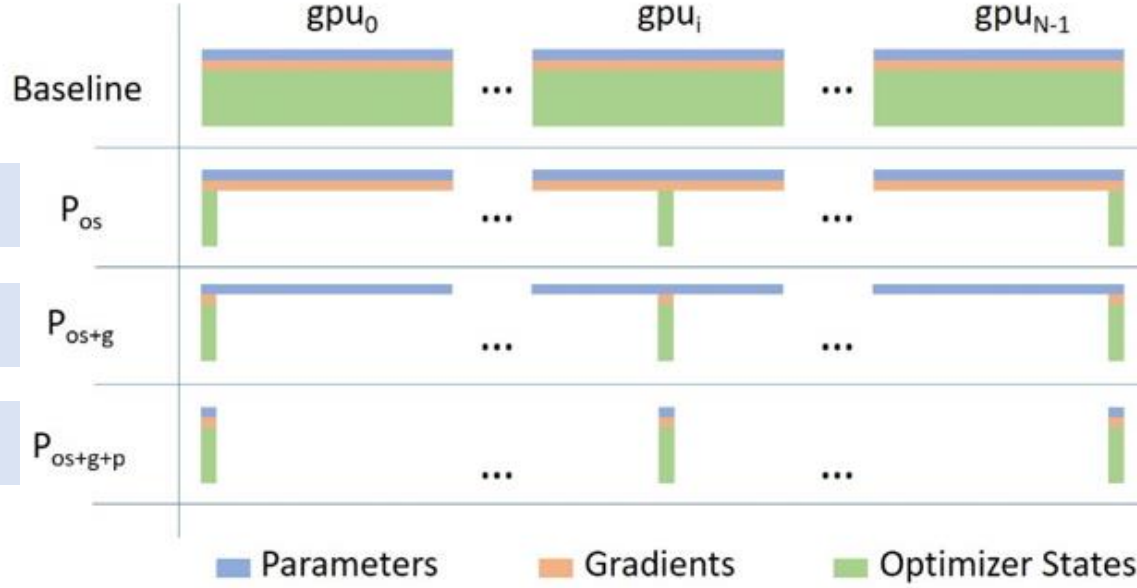

		Memory Consumption		Comm Volume	
		Formulation	Specific Example K=12 Ψ=7.5B N_d=64		
Baseline		$(2+2+K)*\Psi$	120GB	1x	
ZeRO-1	P_{os}	$2\Psi+2\Psi+\frac{K*\Psi}{N_d}$	31.4GB	1x	仅均分优化器参数12P
ZeRO-2	P_{os+g}	$2\Psi+\frac{(2+K)*\Psi}{N_d}$	16.6GB	1x	均分优化器和梯度14P
ZeRO-3	P_{os+g+p}	$\frac{(2+2+K)*\Psi}{N_d}$	1.9GB	1.5x	均分所有16P占用

ZeRO: Memory Optimizations Toward Training Trillion Parameter Models, **SC 2020**

激活值显存估计

- 若保存所有激活值，7B 模型会产生 17GB 激活值占用（推导见教材）

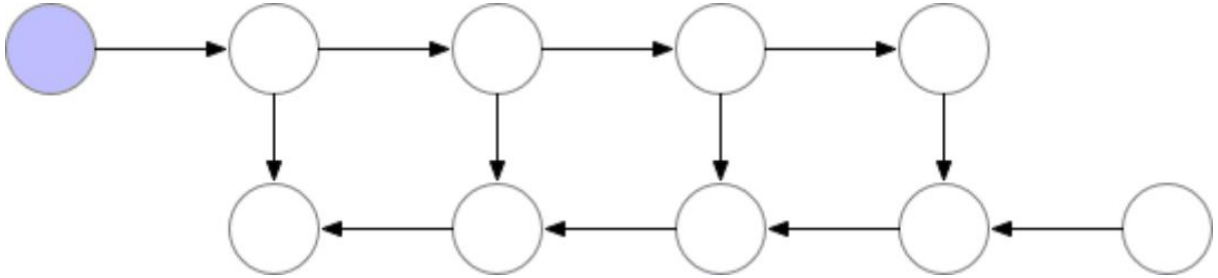

- Transformer训练常保留每一层的输入作为激活值
  - 批次大小为B，则需要 2BTH 字节保存每层输入
  - 还需要 4BTV 字节保存输出层 softmax 输入

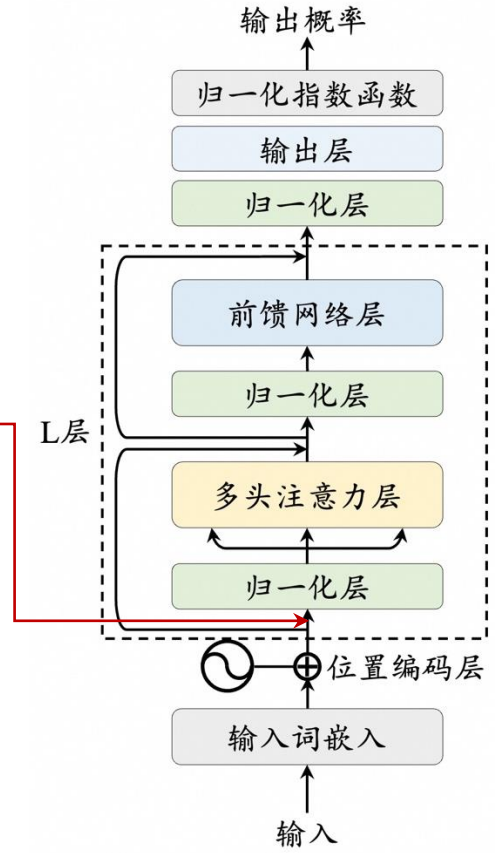

其他显存估计

- 代码库内核
  - PyTorch 框架占用约 1GB
- ZeRO 实现
  - DeepSpeed 占用 1~4GB
- 中间结果
  - 计算输出层 softmax 函数时，Transformers 代码库会额外引入 8BTV 字节显存占用
- 显存碎片
  - 约 1GB

训练显存估计

- 训练时每张GPU显存占用：

$$\underbrace{\frac{16\phi}{N}}_{\text{模型与优化器}} + \underbrace{2LBTH + 12BTV}_{\text{激活值}} + \underbrace{6}_{\text{其他}}$$

- 以 2 张 A100 80G 训练 LLaMA 7B 为例（B=8）
  - 模型与优化器：50GB
  - 激活值：6.2GB
  - 其他：10GB

  } 单卡总计 66GB

谢谢