大模型解码

《大语言模型》编写团队：唐天一

解码策略

AI Box

- 解码：基于输入（提示）生成输出的过程
- 自回归解码：逐词生成下一个词
  - 目前大模型主要采用Transformer 解码器架构

输入： 模型 M，输入词元序列 $\boldsymbol{u}$
输出： 输出词元序列 $\boldsymbol{y}$

1: **repeat**
2: $P = M(\boldsymbol{u})$ # 生成下一个词元的概率分布
3: $u' \sim P$ # 从分布中采样得到下一个词元
4: $\boldsymbol{u} \leftarrow \boldsymbol{u} \oplus [u']$
5: **until** u' 是结束词元或者 $\boldsymbol{u}$ 的长度超过预设长度.
6: $\boldsymbol{y} \leftarrow \boldsymbol{u}$

伪代码：自回归解码流程

解码策略

AI Box

- 贪心搜索：每个生成步骤中都选择概率最高的词元

$$u_i = \arg\max_u P(u \mid \boldsymbol{u}_{<i})$$

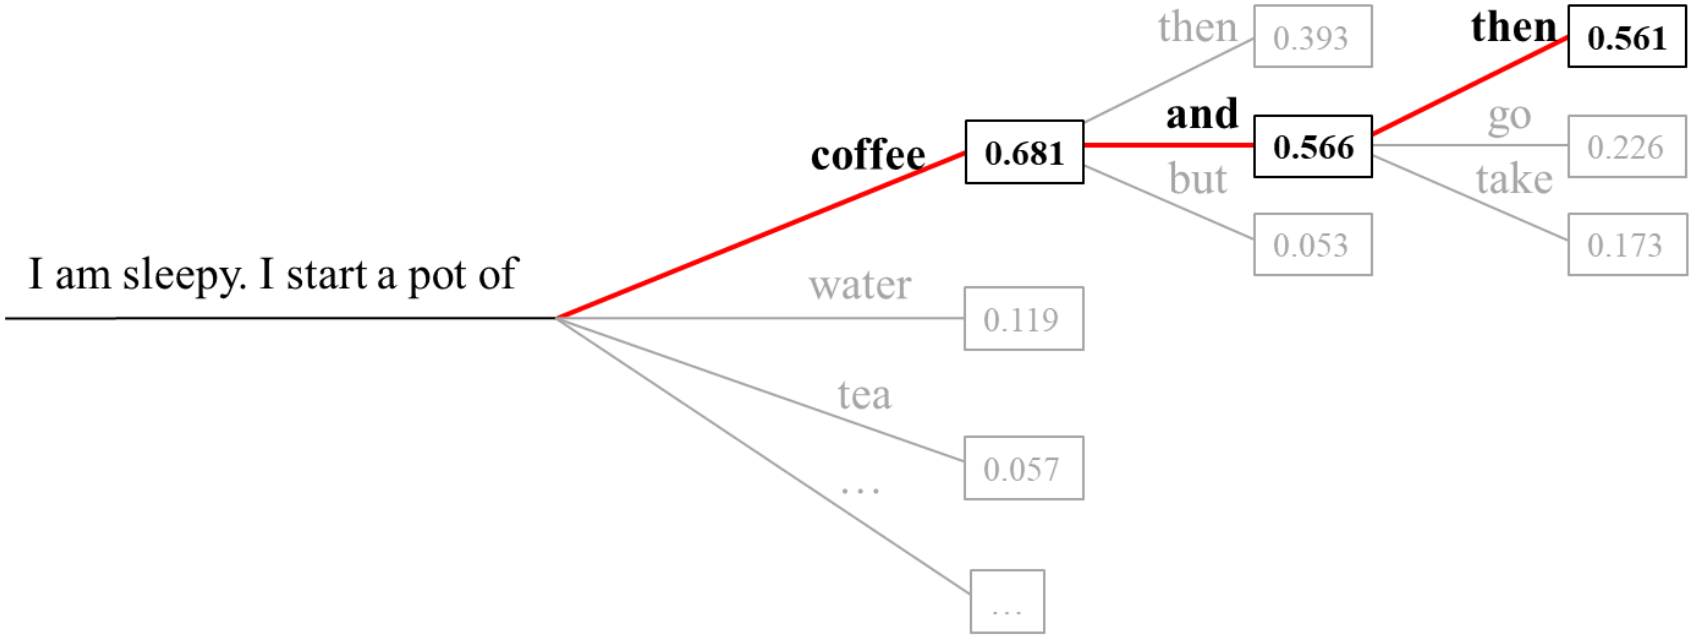

图中红线路径是贪心搜索最后选择的路径

贪心搜索的改进

- 束搜索：每步保留前 n 个具有最高概率的句子
  - 缓解贪心搜索陷入“局部最优”的问题

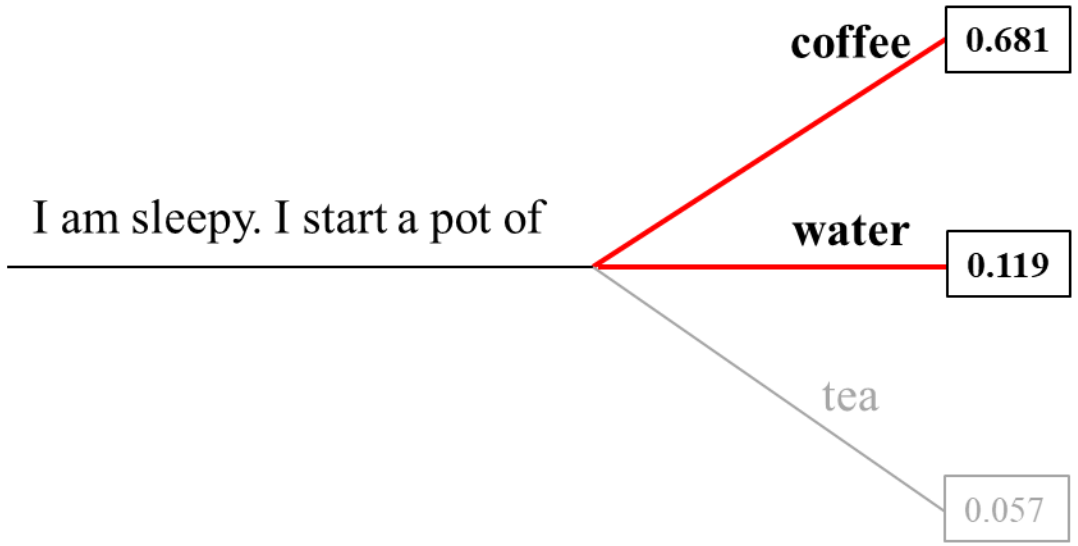

束搜索第一步（n=2）

在第一步解码过程中保留了概率最高的两个单词

贪心搜索的改进

- 束搜索：每步保留前 n 个具有最高概率的句子
  - 缓解贪心搜索陷入“局部最优”的问题

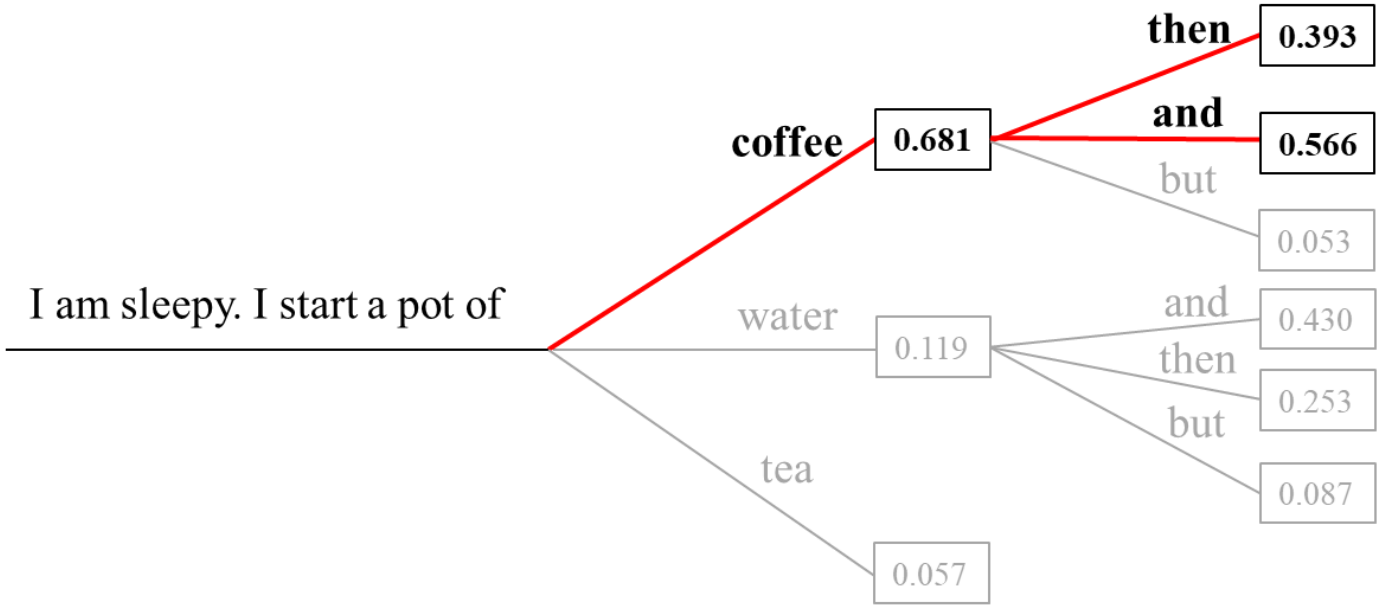

束搜索第二步（n=2）

在第二步解码过程中进一步拓展了两个概率最高的单词

解码策略

AI Box

- 随机采样：基于概率分布采样得到下一个词元
  - 增强结果的多样性

$$u_i \sim P(u \mid \boldsymbol{u}_{<i})$$

I am sleepy. I start a pot of _____

coffee	0.681	strong	0.008	soup	0.005
water	0.119	black	0.008	…	…
tea	0.057	hot	0.007	happy	4.3e-6
rice	0.017	oat	0.006	Boh	4.3e-6
chai	0.012	beans	0.006	…	…

基于文本前缀的下一个词概率分布

随机采样的改进

AI Box

- 温度采样：调整 softmax 函数的温度系数

$$P(u_j \mid \boldsymbol{u}_{<i}) = \frac{\exp(l_j/t)}{\sum_{j'} \exp(l_{j'}/t)}$$

- 降低温度系数，增加高概率词元可能性，降低低概率词元可能性

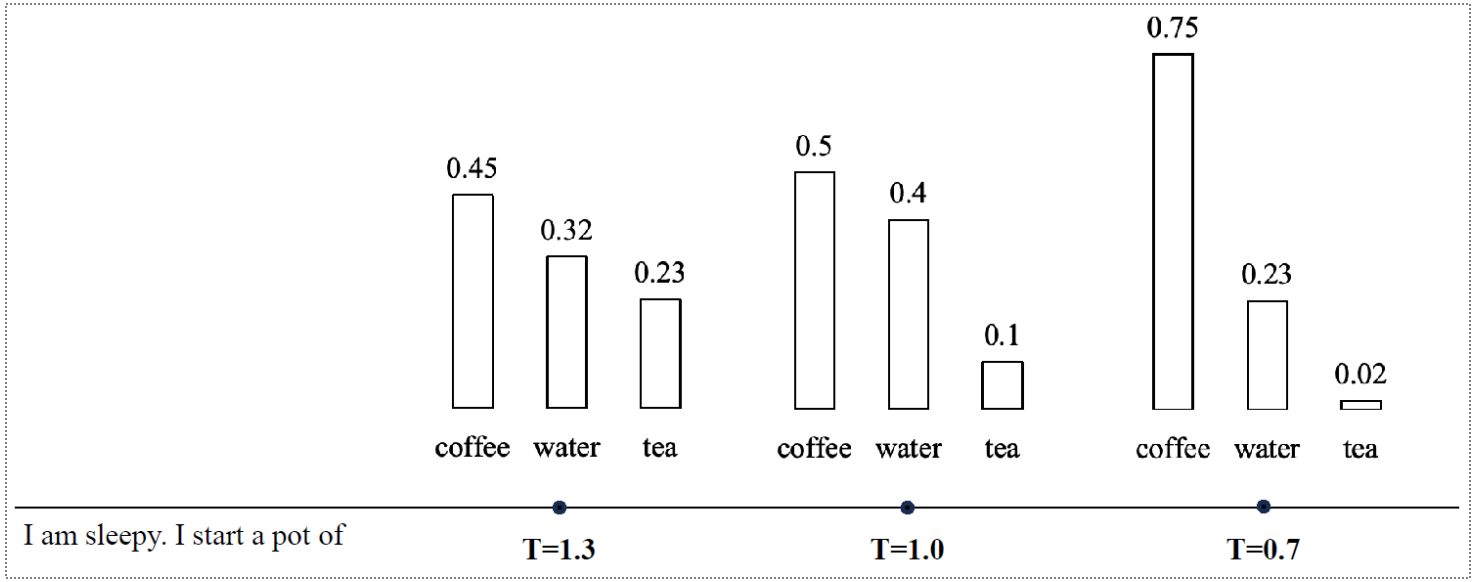

随机采样的改进

- Top-k 采样：仅从概率前 k 高的词元中采样
  - 直接剔除低概率的词，兼顾生成质量

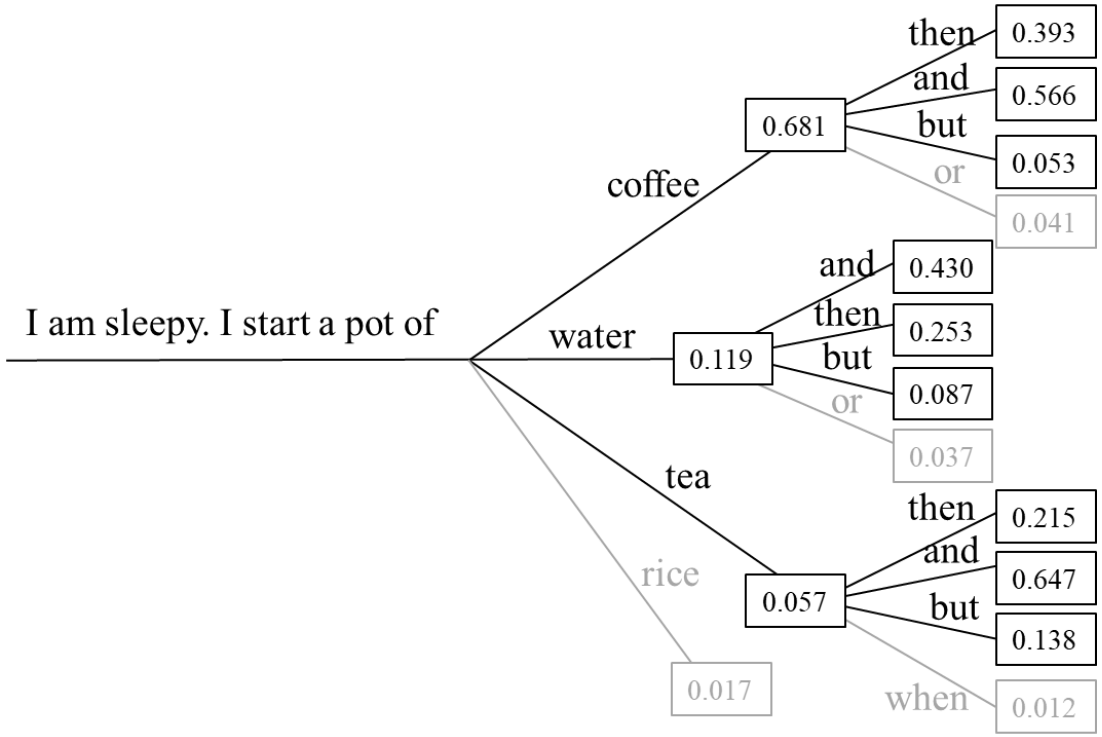

top-k 采样（k=3）

Hierarchical Neural Story Generation, **ACL 2018**

随机采样的改进

AI Box

- Top-p 采样：仅从累积概率和为 p 的高概率词元中采样
  - 考虑整体概率分布，适应不同场景

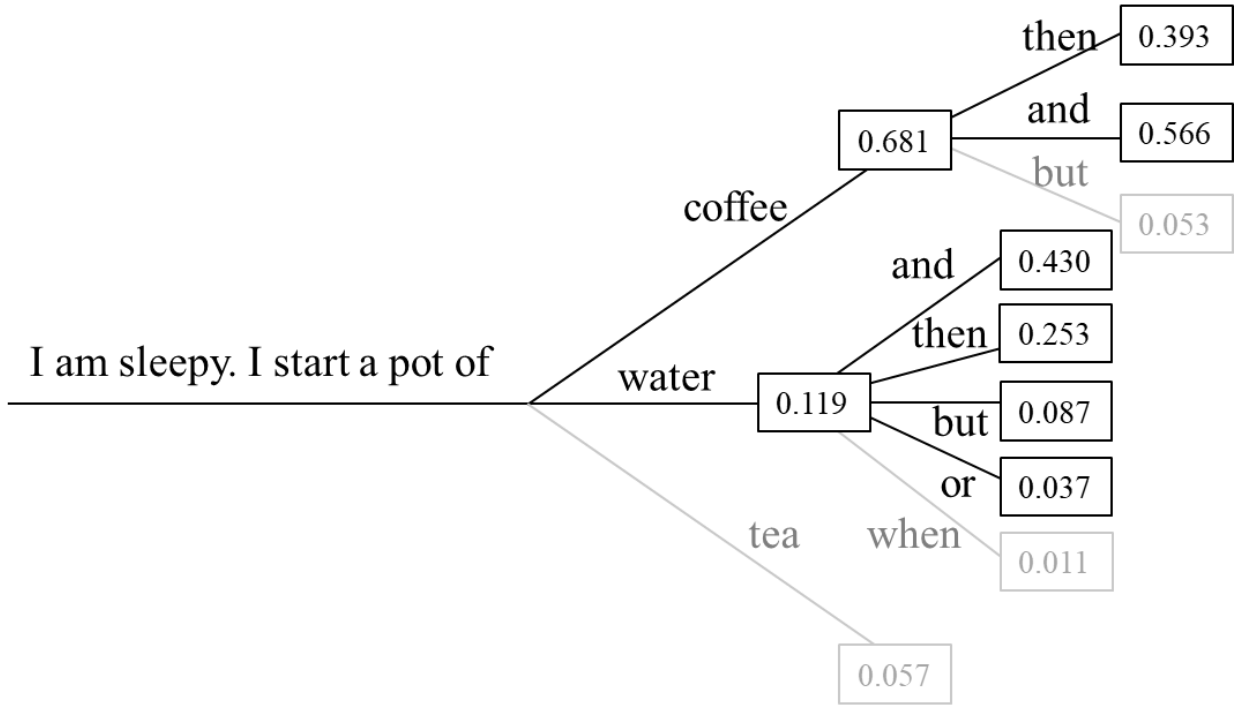

top-p 采样 （p=0.8）

随机采样的改进

AI Box

- 重复惩罚：缓解生成重复文本
  - n-元惩罚
    - 直接避免生成重复的连续 n 个词元（通常$n \in \{3,4,5\}$）
  - 出现惩罚
    - 词元 t 生成的概率 $P(t) = \text{logit}(t) - \text{是否出现}(t) \times \alpha$
  - 频率惩罚
    - 词元 t 生成的概率 $P(t) = \text{logit}(t) - \text{出现次数}(t) \times \alpha$

随机采样的改进

- 对比解码
  - 在大模型和小模型的概率分布差值中采样
- 大模型会为更重要的单词分配更高的概率
  - 借助两者之间的差异发掘重要词汇

李时珍是湖北人，他出生于__

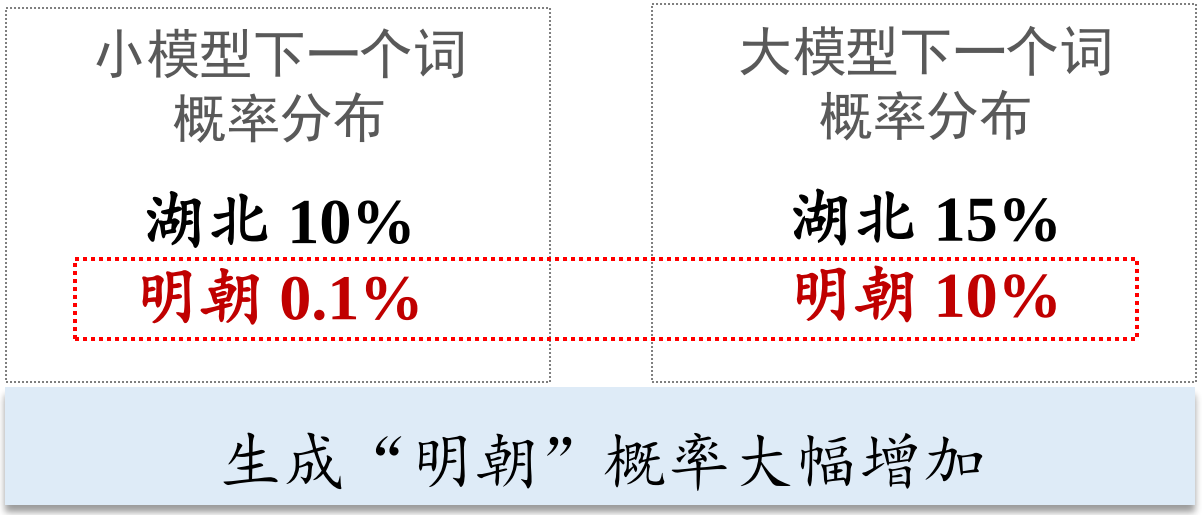

Contrastive Decoding: Open-ended Text Generation as Optimization, **ACL 2023**

谢谢