AI Box

解码效率分析与加速算法

《大语言模型》编写团队：唐天一

解码与键值缓存

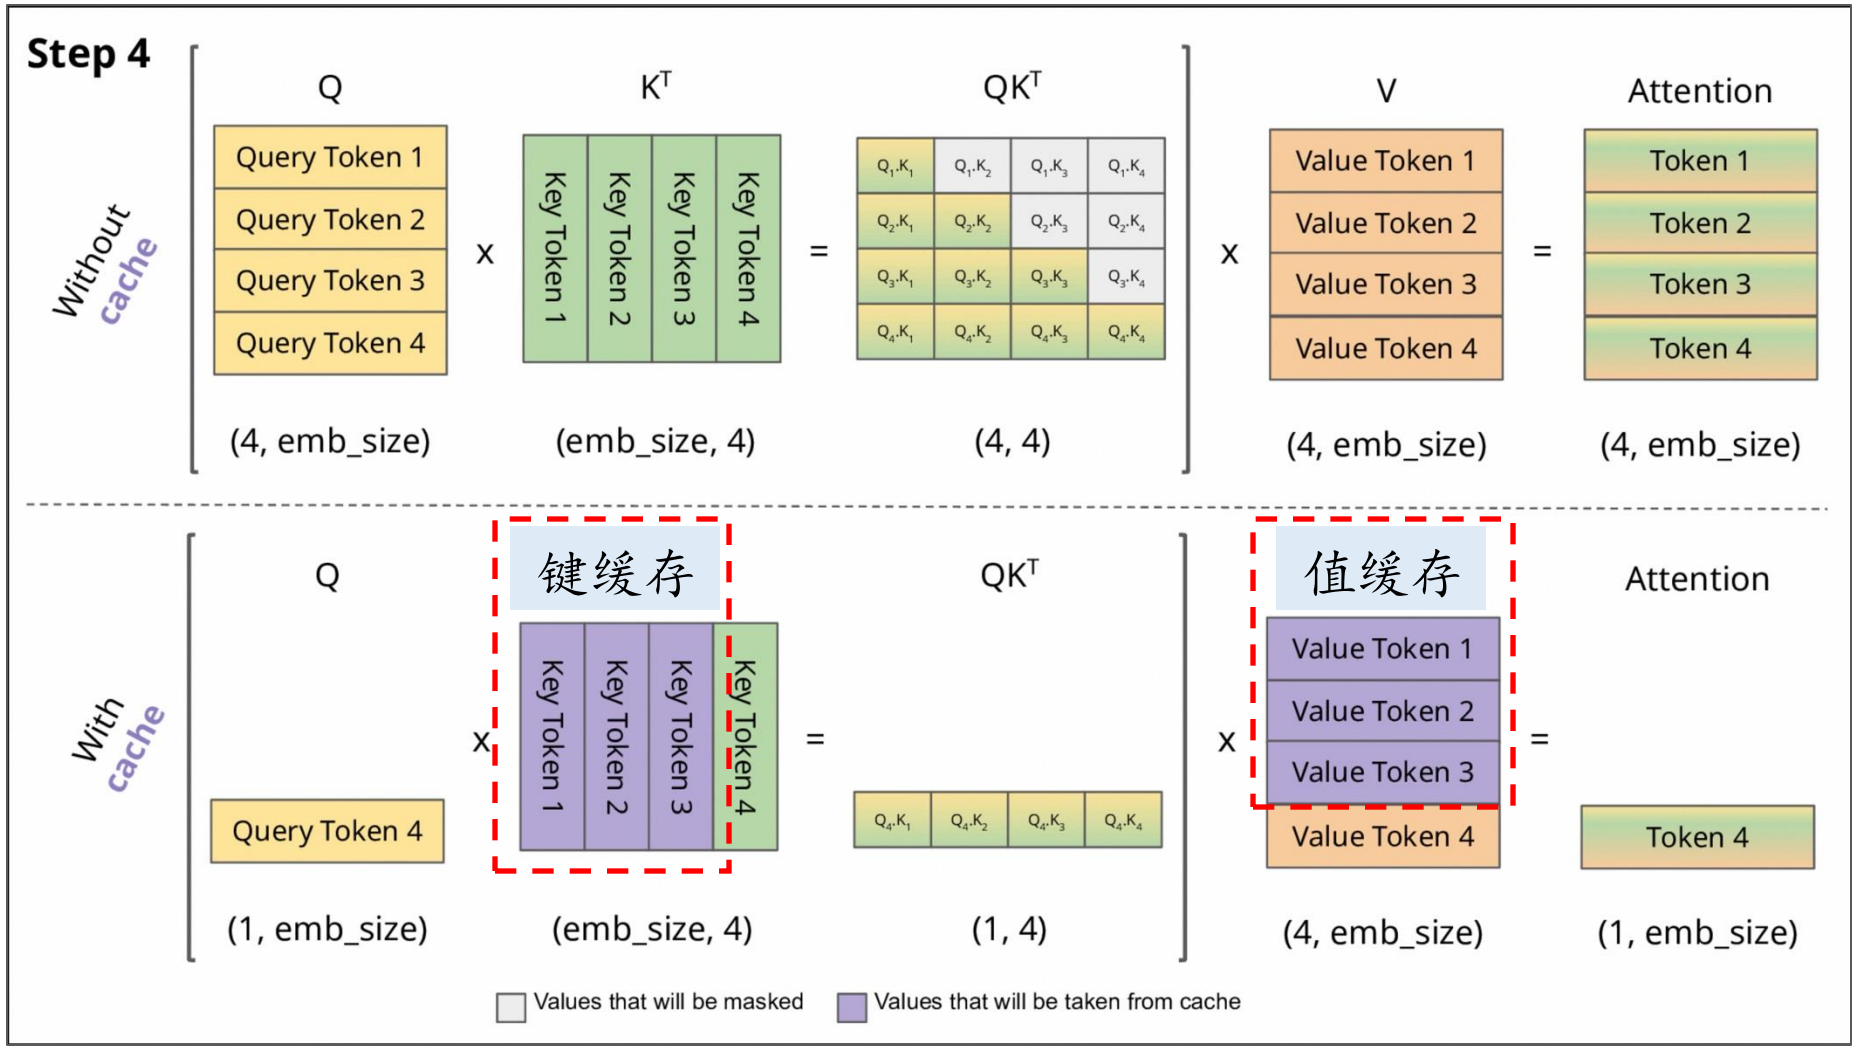

每生成一个词，重新计算所有查询、键、值矩阵

新生成词的查询向量与之前词缓存的键值计算注意力

解码与键值缓存

AI Box

➢ 基于键值缓存优化的贪心解码算法示意图

输入： 模型 $\mathcal{M}$，输入词元序列 $\boldsymbol{u}$
输出： 输出词元序列 $\boldsymbol{y}$

1: $P, \boldsymbol{K}_{past}, \boldsymbol{V}_{past} = \mathcal{M}(\boldsymbol{u})$
2: $u' = \arg\max P$
3: $\boldsymbol{u} \leftarrow \boldsymbol{u} \oplus [u']$

全量解码

4: **while** u' 不是结束词元且 $\boldsymbol{u}$ 的长度不超过预设长度 **do**
5: $P, \boldsymbol{K}, \boldsymbol{V} = \mathcal{M}(u', \boldsymbol{K}_{past}, \boldsymbol{V}_{past})$ # 利用键值缓存计算新生成词元状态
6: $u' = \arg\max P$
7: $\boldsymbol{u} \leftarrow \boldsymbol{u} \oplus [u']$
8: $\boldsymbol{K}_{past}, \boldsymbol{V}_{past} \leftarrow \boldsymbol{K}_{past} \oplus \boldsymbol{K}, \boldsymbol{V}_{past} \oplus \boldsymbol{V}$ # 更新键值缓存
9: **end while**
10: $\boldsymbol{y} \leftarrow \boldsymbol{u}$

解码加速的两个关键

增量解码

$$\text{Attention}(\boldsymbol{q}, \boldsymbol{K}, \boldsymbol{V}) = \text{softmax}(\frac{\boldsymbol{q}\boldsymbol{K}^\top}{\sqrt{D}})\boldsymbol{V}$$

解码效率的定量评估指标

AI Box

GPU 评估指标

算力：每秒的浮点运算次数，FLOP/s

带宽：每秒的显存读写量，byte/s

计算强度上限：算力和带宽的比值

模型评估指标

运算量：所需总浮点运算数，FLOP

访存量：所需总显存读写量，byte

计算强度：运算量和访存量的比值

NVIDIA

A100 (80G)：算力为312 TFLOP/s，带宽为2039 GB/s，计算强度上限约为142.51 FLOP/byte

https://www.nvidia.com/en-us/data-center/a100/

解码效率的定量评估指标

- 效率问题分析
  - 带宽瓶颈
    - 模型计算强度 < GPU 计算强度上限
    - 运行效率主要受显存读写速度的影响
  - 计算瓶颈
    - 模型计算强度 > GPU 计算强度上限
    - 运行效率主要受运算速度的影响

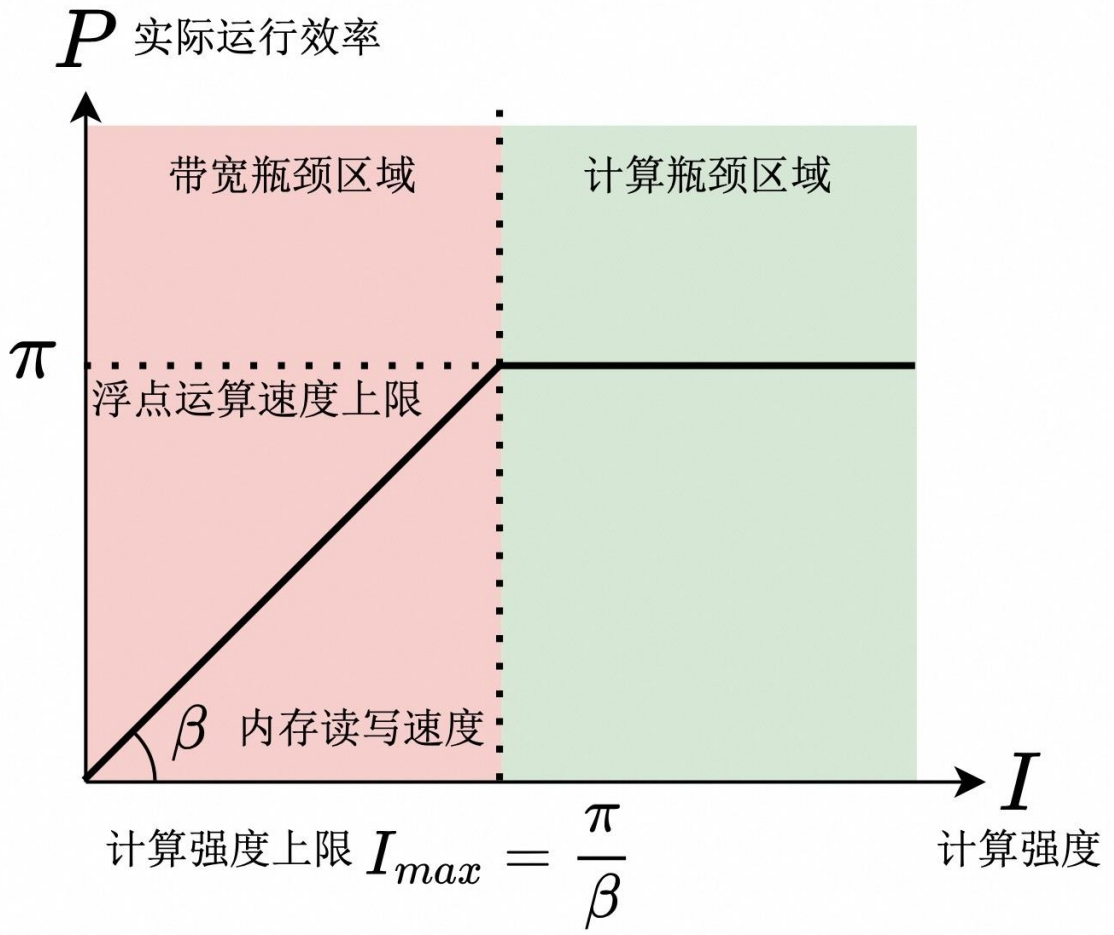

运算量、访存量和计算强度估计

- 矩阵乘法的运算量
  - 矩阵 $\boldsymbol{A} \in \mathbb{R}^{n \times m}$ 和矩阵 $\boldsymbol{B} \in \mathbb{R}^{m \times p}$ 相乘所需的运算量为 $2nmp$
- 矩阵乘法的访存量
  - 矩阵 $\boldsymbol{A} \in \mathbb{R}^{n \times m}$ 和矩阵 $\boldsymbol{B} \in \mathbb{R}^{m \times p}$ 相乘所需的访存量为 $O(nm + mp + np)$
- 矩阵乘法的计算强度
  - 运算量比访存量为 $O(\frac{1}{\frac{1}{n}+\frac{1}{m}+\frac{1}{p}})$

运算量、访存量和计算强度估计

- 张量 $\boldsymbol{X} \in \mathbb{R}^{B\times T\times H}$ 与矩阵 $\boldsymbol{B} \in \mathbb{R}^{H\times H}$ 相乘
  - 运算量：$2BTH^2$
  - 访存量：$O(BTH + H^2)$
  - 计算强度：$O(\frac{1}{\frac{1}{H}+\frac{1}{BT}})$
- 注意力计算 $\text{softmax}\left(\frac{\boldsymbol{QK}^{\mathrm{T}}}{\sqrt{D}}\right)\boldsymbol{V}$，$\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V} \in \mathbb{R}^{B\times T\times N\times D}$
  - 运算量：两次矩阵乘法各 $2BT^2ND$，softmax运算和 $\sqrt{D}$ 放缩共 $4BT^2N$
  - 访存量：两次矩阵乘法 $O(BTND + BT^2N)$，其他运算 $O(BT^2N)$
  - 计算强度：$O(\frac{1+\frac{1}{D}}{\frac{1}{D}+\frac{1}{T}})$

批次大小 B，序列长度 T，隐含层维度 H，注意力头数 N，每个头维度D

运算量、访存量和计算强度估计

AI Box

- 全量解码阶段的计算强度（推导见教材）
  - 线性变换强度约为 2730.7
    - 公式①④⑥⑧
  - 多头注意力强度约为 114.7
    - 公式③
  - 其余操作强度约为 1
    - 公式②⑤⑦⑨

A100 (80G) 的计算强度上限为 142.5

全量解码是**计算瓶颈**的

计算公式	计算强度
① $\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V}=\boldsymbol{X}\boldsymbol{W}^{Q,K,V}$	$O\left(\frac{1}{\frac{1}{H}+\frac{1}{BT}}\right)$
② $\boldsymbol{Q},\boldsymbol{K}=\mathrm{RoPE}(\boldsymbol{Q},\boldsymbol{K})$	$O(1)$
③ $\boldsymbol{O}=\mathrm{Attn}(\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V})$	$O\left(\frac{1+\frac{1}{D}}{\frac{1}{D}+\frac{1}{T}}\right)$
④ $\boldsymbol{X}=\boldsymbol{O}\boldsymbol{W}^{O}$	$O\left(\frac{1}{\frac{1}{H}+\frac{1}{BT}}\right)$
⑤ $\boldsymbol{X}=\mathrm{Add\&Norm}(\boldsymbol{X})$	$O\left(\frac{1}{1+\frac{1}{BT}}\right)$
⑥ $\boldsymbol{G},\boldsymbol{U}=\boldsymbol{X}[\boldsymbol{W}^{G},\boldsymbol{W}^{U}]$	$O\left(\frac{1}{\frac{1}{H}+\frac{1}{H'}+\frac{1}{BT}}\right)$
⑦ $\boldsymbol{D}=\mathrm{Swish}(\boldsymbol{G})\cdot\boldsymbol{U}$	$O(1)$
⑧ $\boldsymbol{X}=\boldsymbol{D}\boldsymbol{W}^{D}$	$O\left(\frac{1}{\frac{1}{H}+\frac{1}{H'}+\frac{1}{BT}}\right)$
⑨ $\boldsymbol{X}=\mathrm{Add\&Norm}(\boldsymbol{X})$	$O\left(\frac{1}{1+\frac{1}{BT}}\right)$

$B=8$　$T=1024$　$H=4096$　$D=128$

运算量、访存量和计算强度估计

AI Box

- 增量解码阶段的计算强度（推导见教材）
  - 将全量解码公式（注意力除外）中 T 变为1
  - 线性变换的计算强度约为 8.0
    - 公式①⑤⑦⑨
  - 多头注意力的计算强度约为 1.0
    - 公式④

计算公式	计算强度
① $\boldsymbol{q},\boldsymbol{k},\boldsymbol{v}=\boldsymbol{x}\boldsymbol{W}^{QKV}$	$O\left(\frac{1}{\frac{1}{H}+\frac{1}{B}}\right)$
② $\boldsymbol{q},\boldsymbol{k}=\mathrm{RoPE}(\boldsymbol{q},\boldsymbol{k})$	$O(1)$
③ $\boldsymbol{K},\boldsymbol{V}=\mathrm{Cache}(\boldsymbol{k},\boldsymbol{v})$	-
④ $\boldsymbol{o}=\mathrm{Attn}(\boldsymbol{q},\boldsymbol{K},\boldsymbol{V})$	$O\left(\frac{1+\frac{1}{D}}{1+\frac{1}{D}+\frac{1}{T}}\right)$
⑤ $\boldsymbol{x}=\boldsymbol{o}\boldsymbol{W}^{O}$	$O\left(\frac{1}{\frac{1}{H}+\frac{1}{B}}\right)$
⑥ $\boldsymbol{x}=\mathrm{Add\&Norm}(\boldsymbol{x})$	$O\left(\frac{1}{1+\frac{1}{B}}\right)$
⑦ $\boldsymbol{g},\boldsymbol{u}=\boldsymbol{x}[\boldsymbol{W}^{G},\boldsymbol{W}^{U}]$	$O\left(\frac{1}{\frac{1}{H}+\frac{1}{H'}+\frac{1}{B}}\right)$
⑧ $\boldsymbol{d}=\mathrm{Swish}(\boldsymbol{g})\cdot\boldsymbol{u}$	$O(1)$
⑨ $\boldsymbol{x}=\boldsymbol{d}\boldsymbol{W}^{D}$	$O\left(\frac{1}{\frac{1}{H}+\frac{1}{H'}+\frac{1}{B}}\right)$
⑩ $\boldsymbol{x}=\mathrm{Add\&Norm}(\boldsymbol{x})$	$O\left(\frac{1}{1+\frac{1}{B}}\right)$

$B=8$　$T=1024$　$H=4096$　$D=128$

A100 (80G) 的计算强度上限为 142.5

增量解码是带宽瓶颈（“内存墙”问题）

系统级优化

AI Box

- FlashAttention
  - 改进注意力计算 $\text{softmax}\left(\frac{\boldsymbol{QK}^{\top}}{\sqrt{D}}\right)\boldsymbol{V}$
  - 通过矩阵分块和算子融合，减少中间结果读写，减少访存量

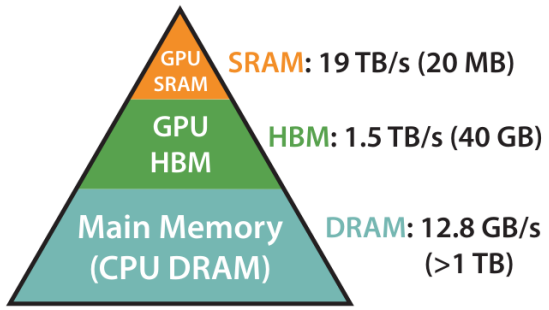

Memory Hierarchy with Bandwidth & Memory Size

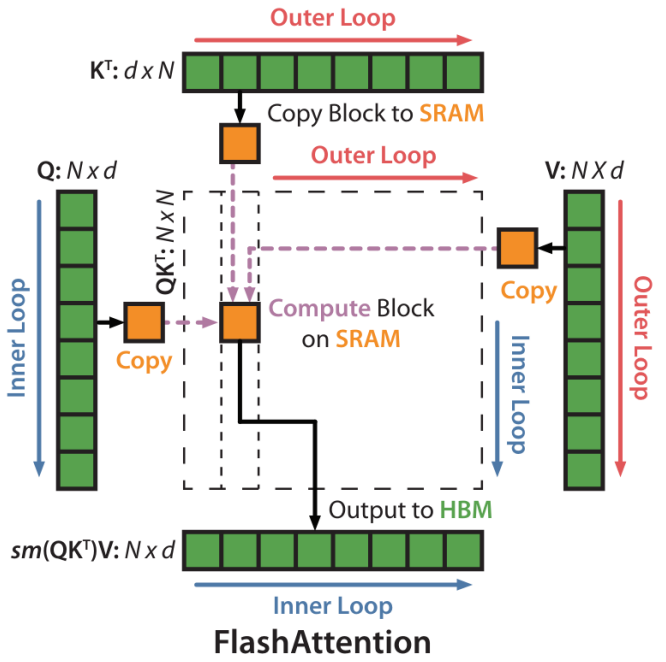

FlashAttention

将 QKV 分块计算，在 SRAM 中直接计算得到最终结果

系统级优化

- PagedAttention
  - 优化键值缓存更新操作 $\boldsymbol{K}' = \boldsymbol{K} \oplus (\boldsymbol{x}_{u'}\boldsymbol{W}^K)$ 和 $\boldsymbol{V}' = \boldsymbol{V} \oplus (\boldsymbol{x}_{u'}\boldsymbol{W}^V)$
  - 通过显存分页减少拼接时显存反复分配，同时提升注意力计算效率

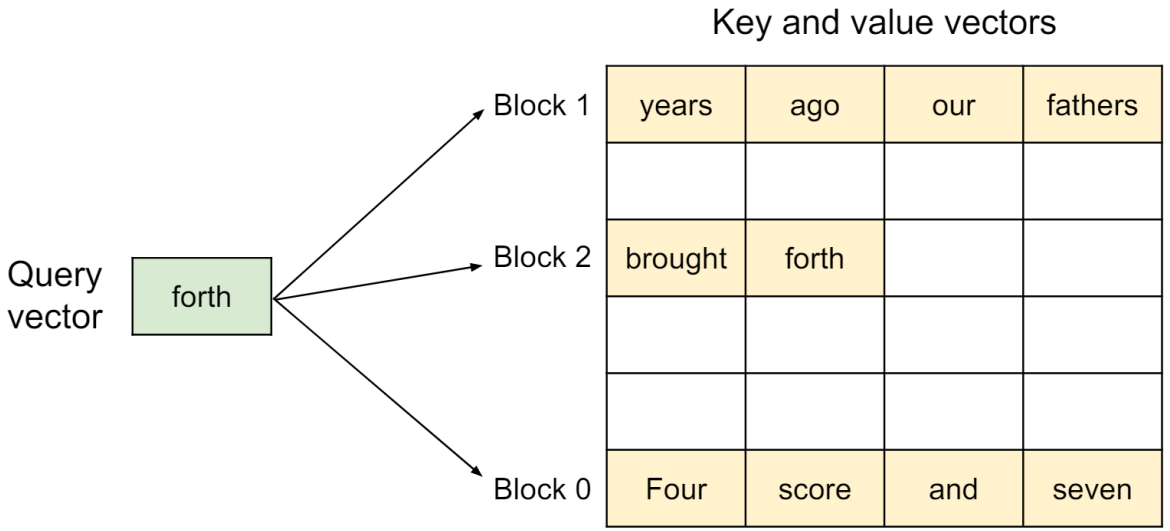

显存分页

查询与多个键值块并行计算

系统级优化

- 传统批次推理：一个批次全部推理完成才进行下一个
- 批次管理优化：将每个请求进行分割，提升实际运行批次
  - 连续批处理
    - 分割为一个全量解码和若干个单步增量解码
    - 启发式选择部分请求全量解码或单步增量解码
  - 动态分割
    - 将全量解码进一步拆分
    - 同时进行全量解码和增量解码

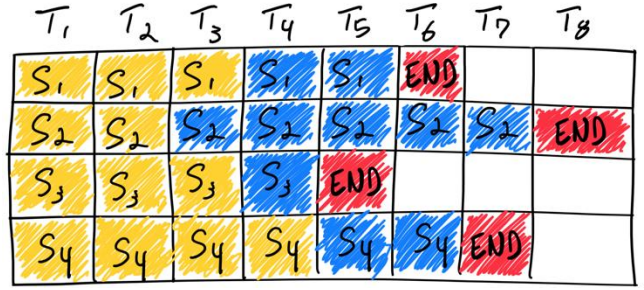

传统批次推理

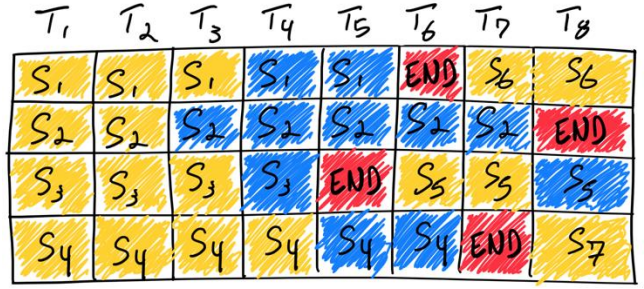

批次管理优化

https://www.anyscale.com/blog/continuous-batching-llm-inference

解码策略优化

AI Box

- 推测解码
  - 先用小且高效的模型自回归地生成 3～5 个词元
  - 再由大模型对这个片段进行一次验证，进行拒绝与修改
  - 不会降低大模型解码质量，一般带来两倍左右加速

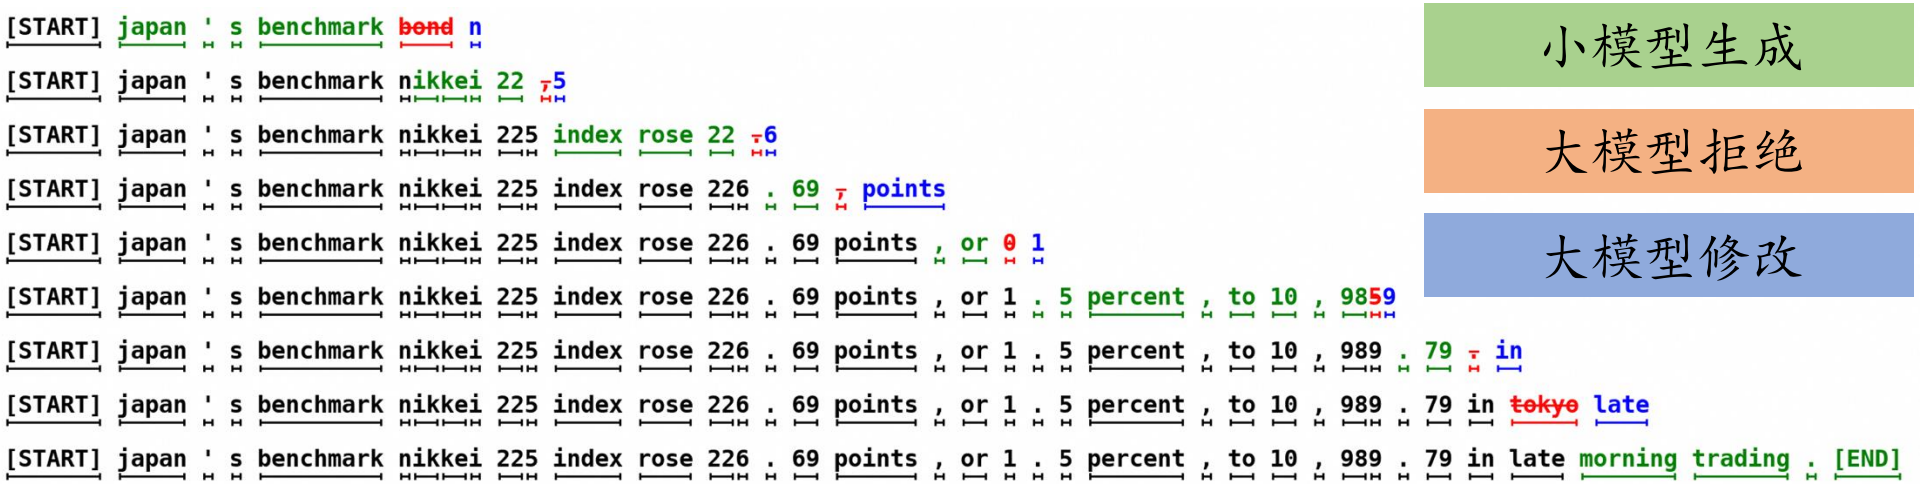

Fast Inference from Transformers via Speculative Decoding, **ICML 2023**

解码策略优化

AI Box

- 推测解码流程示例（视频演示）

https://huggingface.co/blog/assisted-generation

解码策略优化

AI Box

- 级联解码
  - 引入一系列模型，按照效率从高到低排序
  - 依次让模型生成答案，由二分类器判断
  - 如果结果可靠则不需要后续生成

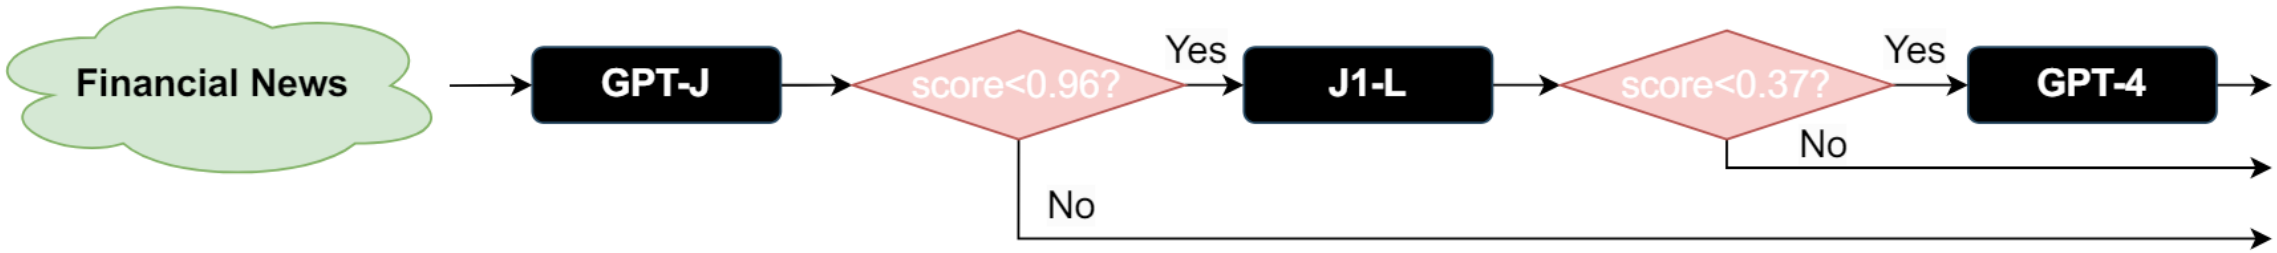

通过优先让相对较小模型进行解码，减少更大模型的调用开销

FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance. **arXiv 2023**

解码策略优化

- 非（半）自回归解码
  - 非自回归解码：基于输入一次性生成所有词元
  - 半自回归解码：组内非自回归生成，组间自回归生成

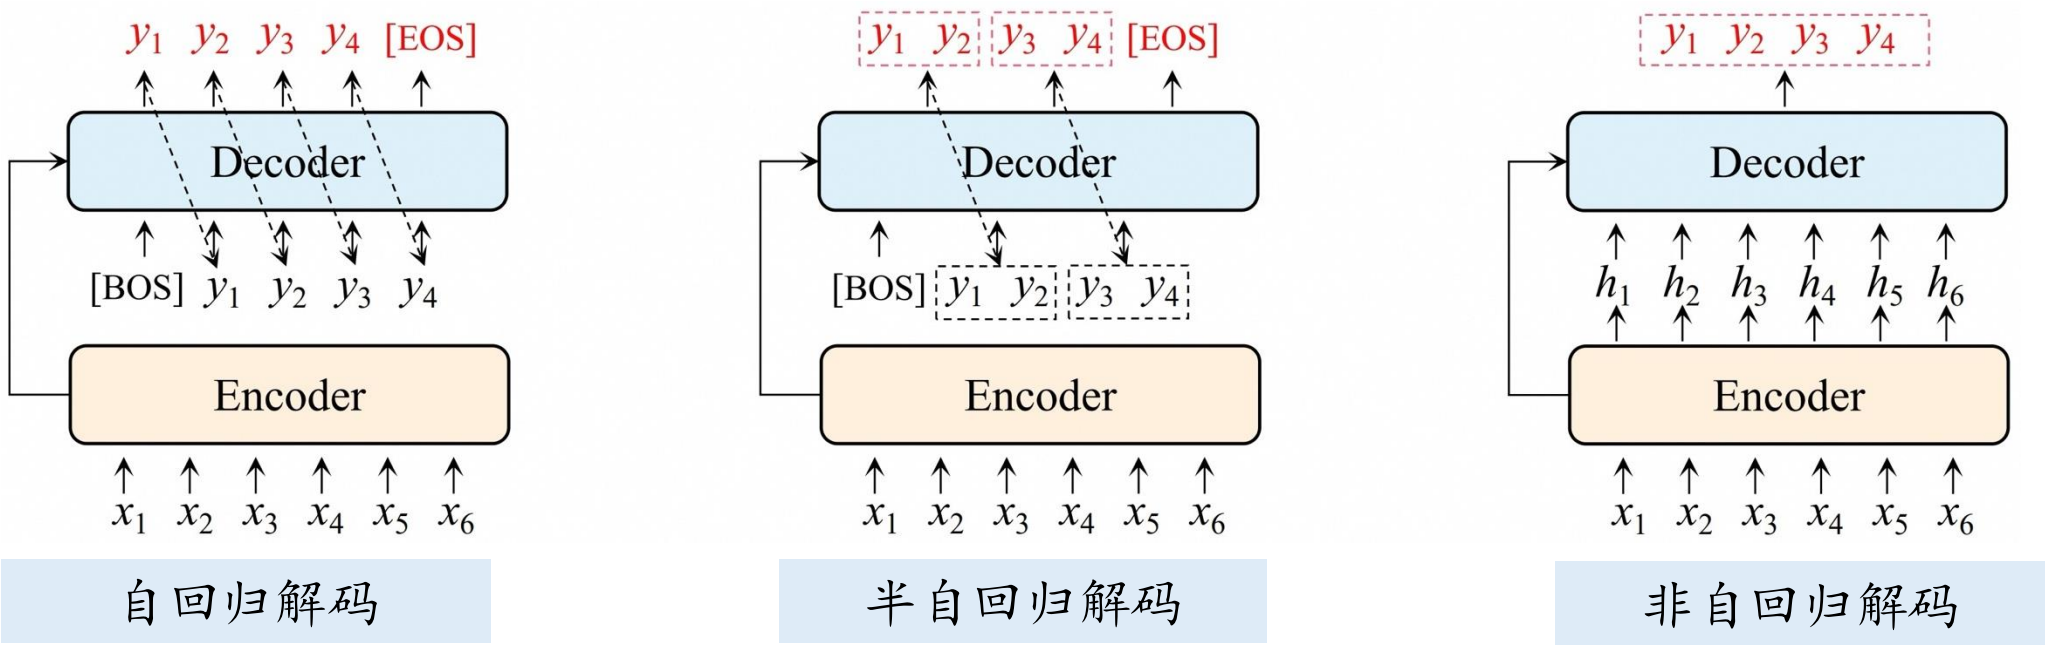

A Survey on Non-Autoregressive Generation for Neural Machine Translation and Beyond. **PAMI 2023**

解码策略优化

- 非（半）自回归解码
  - 非自回归解码：基于输入一次性生成
  - 半自回归解码：组内非自回归，组间自回归
- Medusa
  - 额外训练两个预测头分别预测第二个词和第三个词
  - 结合推测解码，加速原始大模型生成
  - 不影响生成质量，推理加速 2.2 倍

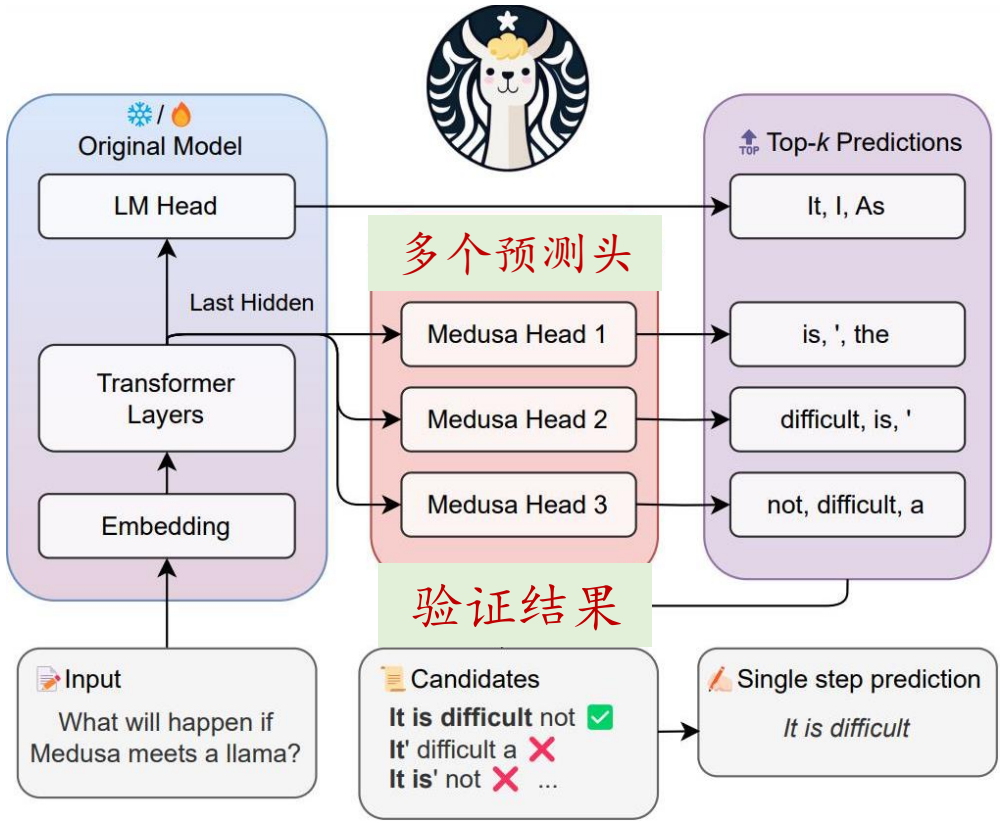

Medusa: Simple LLM Inference Acceleration Framework with Multiple Decoding Heads. **ICML 2024**

解码策略优化

AI Box

- 早退机制
  - 不需要所有层计算，满足条件跳过后续层计算
  - 每层得到输出概率分布，计算分布的熵值；如果熵值较低，则提前退出

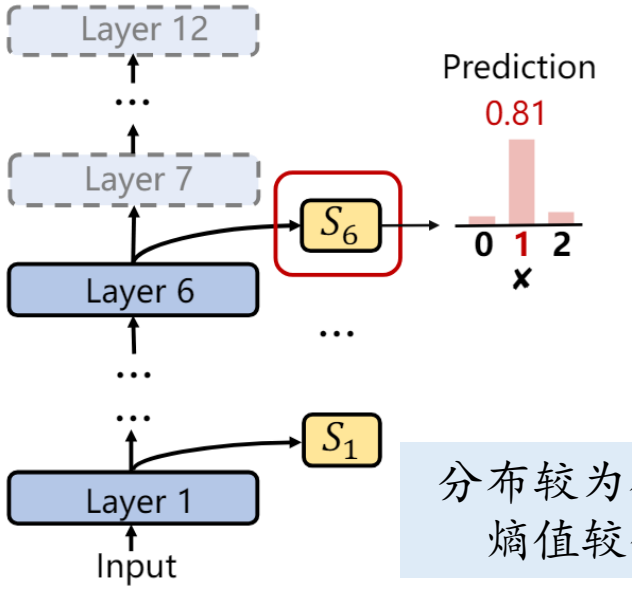

Model	MNLI-m Acc	MNLI-m Spd-up	MNLI-mm Acc	MNLI-mm Spd-up	QQP F1/Acc	QQP Spd-up	QNLI Acc	QNLI Spd-up	SST-2 Acc	SST-2 Spd-up	MRPC F1/Acc	MRPC Spd-up	RTE Acc	RTE Spd-up	Macro
BERT															
BERT-base (Devlin et al., 2019)	84.6	1.00×	83.4	1.00×	71.2/ -	1.00×	90.5	1.00×	93.5	1.00×	88.9/ -	1.00×	66.4	1.00×	-
BERT-6L	80.8	2.00×	79.9	2.00×	69.7/88.3	2.00×	86.7	2.00×	91.0	2.00×	85.1/78.6	2.00×	63.9	2.00×	80.5
DeeBERT (Xin et al., 2020)	-		-	-	69.4/ -	1.96×	87.9	1.79×	91.5	1.89×	85.2/ -	1.79×	-	-	-
DeeBERT	74.4	1.87×	73.1	1.88×	70.4/88.8	2.13×	85.6	2.09×	90.2	2.00×	84.4/77.4	2.07×	64.3	1.95×	74.7
PABEE	79.8	2.07×	78.7	2.08×	70.4/88.6	2.09×	88.0	1.87×	89.3	1.95×	84.4/77.4	2.01×	64.0	1.81×	80.0
Ours	**83.3**	1.96×	**82.7**	1.96×	**71.2/89.4**	2.18×	**89.8**	1.97×	**92.8**	2.02×	**87.0/81.8**	1.98×	**64.5**	2.04×	**82.5**
RoBERTa															
RoBERTa-base (Xin et al., 2020)	87.0	1.00×	86.3	1.00×	71.8/ -	1.00×	92.4	1.00×	94.3	1.00×	90.4/ -	1.00×	67.5	1.00×	-
RoBERTa-6L	84.4	2.00×	83.4	2.00×	71.6/89.2	2.00×	90.4	2.00×	93.5	2.00×	**89.3/85.5**	2.00×	58.0	2.00×	82.5
DeeBERT	64.2	1.87×	64.7	1.87×	**72.0/89.3**	2.05×	83.8	2.01×	86.9	2.02×	88.7/84.3	1.86×	**60.8**	1.90×	75.4
Ours	**86.6**	1.92×	**86.2**	1.93×	**72.0/89.3**	2.54×	**91.7**	2.11×	**94.5**	1.98×	**89.3/85.5**	1.95×	58.0	2.11×	**83.6**
ALBERT															
ALBERT-base	85.2	1.00×	84.7	1.00×	70.5/88.7	1.00×	92.0	1.00×	93.3	1.00×	89.0/84.8	1.00×	72.0	1.00×	84.8
ALBERT-6L	82.4	2.00×	81.7	2.00×	69.8/88.3	2.00×	90.0	2.00×	91.8	2.00×	87.0/82.4	2.00×	65.8	2.00×	82.2
PABEE	84.2	1.90×	83.5	1.81×	**70.7/88.9**	2.11×	90.9	1.98×	92.4	1.80×	87.6/82.6	1.91×	66.8	2.06×	83.2
Ours	**84.8**	1.94×	**84.1**	1.95×	70.4/88.6	2.35×	**91.9**	1.97×	**92.8**	2.13×	**88.3/84.6**	1.95×	**72.0**	1.93×	**84.5**

AGlobal Past-Future Early Exit Method for Accelerating Inference of Pre-trained Language Models, **NAACL 2021**

解码策略优化

AI Box

- 早退机制
  - 不需要所有层计算，满足条件跳过后续层计算
  - 每层得到输出概率分布，计算分布的熵值
  - 如果熵值较低，则提前退出
  - 混合深度方法（借鉴 MoE）
    - 每层根据路由网络判定是否进行该层计算
    - 可以平衡时间开销，最多减少 50% 计算开销

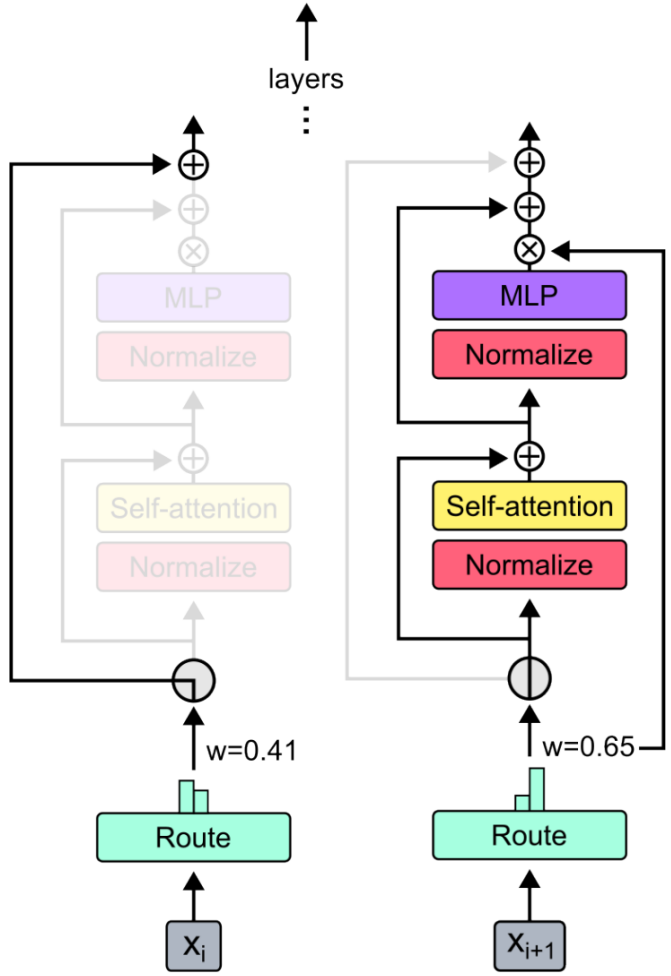

Mixture-of-Depths: Dynamically allocating compute in transformer-based language models. **arXiv 2024**

谢谢